


2023 届硕士专业学位研究生学位论文

分类号: _____

学校代码: 10269

密级: _____

学号: 71194501227



華東師範大學

East China Normal University

硕士专业学位论文

Master's Degree Thesis (Professional)

论文题目: 银行业舆情数据采集与 分析系统的设计与实现

院 系: 软件工程学院

专业学位类别: 工程硕士

专业学位领域: 软件工程

学位申请人: 尤豪谦

指导教师: 王丽苹(副)教授

2023 年 11 月 16 日

Thesis for Master's Degree (Professional) in 2023

University code:10269

Student ID: 71194501227

East China Normal University

Title:**Design and Implementation of
Public Sentiment Data Acquisition
and Analysis System for Banking**

Department/School: Software Engineering Institute

Category: Master of Engineering

Field: Software Engineering

Candidate: YOU Haoqian

Supervisor: Wang Liping(Associate)Professor

Nov, 2023

尤豪谦 硕士学位论文答辩委员会成员名单

姓名	职称	单位	备注
刘晓强	教授	东华大学	主席
王高丽	教授	华东师范大学	
王江涛	高级工程师	华东师范大学	

中文摘要

据官方统计数据所示,截至 2021 年底,全国范围内共计开立 136.64 亿个银行账户,电子支付业务笔数高达 2749.69 亿笔,累计金额 2976.22 万亿元。随着银行账户的增加及支付等业务的不断增长,银行业越来越成为国家的经济命脉与强力支柱。在网络舆情这种新型社会舆情生态环境下,银行业的舆情风险管理工作面临着极大挑战,一旦掀起舆情风波,银行的信用受到冲击,后果不堪设想。轻则品牌名誉受损,重则引发金融风险。正是因为银行业缺乏能根据自身业务经营需要来进行舆情文本数据采集与分析的能力,所以文本信息的不断增长与扩散为银行业舆情数据采集与分析管理带来严峻挑战。因此,本文提出了专属银行业的舆情数据采集与分析系统的研究,设计并实现了该系统。

本文立足银行业舆情数据采集与分析场景,研究的主要工作内容为:

(1) 调研国内外银行业舆情数据采集与分析系统的现状,对现流行的银行业舆情数据采集与分析技术进行分析,挖掘其可以改进优化以及替代的部分。提出基于窗口改进的层次狄利克雷过程采样消息传递算法和基于中心词改进的层次狄利克雷过程采样消息传递算法,在进行舆情文本主题提取时保留上下文语义与顺序的同时提升计算速度。

(2) 使用 Scrapy 爬虫框架对各大金融主流网站的舆情文本进行采集,构建本文实验的数据集以及适配银行领域专业性与特殊性的银行业专属情感词典,并结合改进的主题模型与基于情感词典以及预训练模型的情感分析算法对采集的舆情文本数据进行分析。

(3) 通过分析设计、开发测试,最终实现一个银行业普适的稳定的舆情数据采集与分析系统,包括数据采集、数据处理、数据加工、数据分析、信息配置等功能模块。

通过本系统的建立,满足了银行业在舆情文本方面的经营管理需要,日后还将继续借力新技术推进银行业自主研发的舆情数据采集与分析系统的完善与落地,站在人工智能新时代更好地拥抱科技新力量。

关键词：主题模型，情感分析，银行业，舆情分析，系统设计

ABSTRACT

According to official statistics, as of the end of 2021, a total of 13.664 billion bank accounts were opened nationwide, with a total of 274.969 billion electronic payment transactions and a total amount of 2976.22 trillion yuan. With the increase of bank accounts and the continuous growth of payment and other businesses, the banking industry has increasingly become the economic lifeline and strong pillar of the country. In the new social public opinion ecological environment of online public opinion, the management of public opinion risk in the banking industry is facing great challenges. However, once a public opinion storm is triggered, the credit of banks is affected, and the consequences are unimaginable. At a mild level, brand reputation may be damaged, while at a severe level, financial risks may arise. It is precisely because the banking industry lacks the ability to collect and analyze public opinion text data based on its own business needs that the continuous growth and diffusion of text information poses serious challenges to the collection and analysis management of public opinion data in the banking industry. Therefore, this article proposes the research and implementation of a public opinion data collection and analysis system for the exclusive banking industry.

This article is based on the scenario of collecting and analyzing public opinion data in the banking industry, and the main work content of the study is:

(1) Research the current status of public opinion data collection and analysis systems in the domestic and foreign banking industry, analyze the current popular technology for collecting and analyzing public opinion data in the banking industry, and explore the parts that can be improved, optimized, and replaced. Propose a hierarchical Dirichlet process sampling message passing algorithm based on window improvement and a hierarchical Dirichlet process sampling message passing algorithm based on central word improvement, which preserves contextual semantics and order while improving computational speed when extracting public opinion text

topics.

(2) Use the Scrapy crawler framework to collect public opinion texts from major financial mainstream websites, construct the dataset for this experiment and a banking industry specific sentiment dictionary that adapts to the professionalism and specificity of the banking field. Combine the improved theme model with sentiment analysis algorithms based on sentiment dictionaries and pre trained models to analyze the collected public opinion text data.

(3) Through analysis, design, development, and testing, a universal and stable public opinion data collection and analysis system for the banking industry is ultimately achieved, including functional modules such as data collection, data processing, data processing, data analysis, and information configuration.

Through the establishment of this system, the business management needs of the banking industry in terms of public opinion texts have been met. In the future, we will continue to leverage new technologies to promote the improvement and implementation of the independently developed public opinion data collection and analysis system in the banking industry, and better embrace new technological forces in the new era of artificial intelligence.

Keywords:*[Theme model][emotional analysis][banking][public opinion analysis][system design]*

目 录

第一章 绪论.....	1
1.1 论文研究背景及意义.....	1
1.1.1 研究背景.....	1
1.1.2 研究意义.....	2
1.2 论文相关研究现状.....	3
1.2.1 银行业舆情数据采集应用现状.....	3
1.2.2 银行业舆情数据分析应用现状.....	4
1.2.3 主题模型研究现状.....	5
1.2.4 情感分析研究现状.....	6
1.3 论文主要内容与贡献.....	8
1.3.1 论文主要内容.....	8
1.3.2 贡献.....	9
1.4 论文组织结构.....	10
第二章 相关理论与知识研究	12
2.1 舆情数据采集相关技术.....	12
2.2 舆情数据分析相关技术.....	12
2.2.1 HDP 模型.....	13
2.2.2 消息传递算法.....	14
2.2.3 情感分析技术.....	15
2.2.4 文本分类技术.....	16
2.3 系统设计与实现相关技术	17
2.3.1 Web 开发框架.....	17
2.3.2 Spring 框架	17
2.3.3 DB2 数据库	18
2.3.4 Java 开发语言.....	18
2.3.5 Python 开发语言	18
2.3.6 JIEBA 分词工具.....	19
第三章 构建银行业舆情分析模型	20
3.1 模型设计框架.....	20
3.2 构建专属情感词典.....	21
第四章 构建主题模型	27
4.1 基于窗口的 HDP 采样消息传递模型	27
4.1.1 WHDP 采样消息传递模型.....	27
4.1.2 WHDP 采样消息传递模型的近似推理方法.....	29

4.1.3 WHDP 采样消息传递模型的实验分析	33
4.2 基于中心词的 HDP 采样消息传递模型	36
4.2.1 CHDP 采样消息传递模型	36
4.2.2 CHDP 采样消息传递模型的近似推理方法	36
4.2.3 CHDP 采样消息传递模型实验分析	39
4.3 本章小结	42
第五章 构建情感分析模型	43
5.1 基于情感词典的情感分析方法	43
5.1.1 模型原理	43
5.1.2 实验分析	44
5.1.3 局限性	44
5.2 基于预训练模型的舆情文本情感分类方法	45
5.2.1 预训练编码器	45
5.2.2 BAG 模型设计	46
5.2.3 BAG 模型实验分析	47
5.3 基于大模型的舆情文本情感分类方法	49
5.3.1 大模型设计	49
5.3.2 大模型实验分析	49
5.3.3 局限性	51
5.4 本章小结	52
第六章 系统的设计与实现	53
6.1 系统需求分析	53
6.1.1 业务流程分析	53
6.1.2 系统功能性需求分析	54
6.1.3 系统需求用例	55
6.1.4 系统非功能性需求分析	56
6.2 系统设计	58
6.2.1 系统业务架构设计	58
6.2.2 系统技术架构设计	60
6.2.3 系统部署架构设计	61
6.2.4 系统功能模块详细设计	63
6.2.5 系统数据库设计	71
6.3 系统实现	76
6.3.1 系统首页实现	76
6.3.2 系统配置中心实现	77
6.3.3 系统报告中心实现	78
6.4 系统测试	78
6.4.1 测试方法	78

6.4.2 测试用例.....	79
6.4.3 测试结果.....	81
总结与展望.....	82
参考文献.....	84

插图目录

图 1-1	LSTM 结构	7
图 1-2	GRU 单元	7
图 2-1	网络爬虫工作流程示意图	12
图 2-2	HDP 模型图	13
图 2-3	基于情感词典的文本情感分类方法	15
图 2-4	文本情感值计算流程	16
图 3-1	银行业舆情分析模型设计框架图	20
图 3-2	情感分析五要素	22
图 3-3	银行领域情感词典构成	22
图 3-4	爬虫采集的舆情文本数据示例	23
图 3-5	PMI 结果示意图	24
图 3-6	SO-PMI 结果示意图	24
图 4-1	WHDP 采样消息传递模型	28
图 4-2	WHDP 采样消息传递模型因子图	29
图 4-3	混淆度变化曲线	34
图 4-4	多模型混淆度对比分析	34
图 4-5	WHDP 模型 500 次实验主题分布	35
图 4-6	多模型相似度对比分析	36
图 4-7	CHDP 采样消息传递模型因子图	37
图 4-8	混淆度变化曲线	40
图 4-9	多模型混淆度对比分析	41
图 4-10	CHDP 模型 500 次实验的主题分布	41
图 4-11	多模型间相似度对比分析	42
图 5-1	基于情感词典的文本情感分类方法	43
图 5-2	BERT 文本嵌入	45
图 5-3	BGA	46

图 5-4	BGA 模型准确率与损失值变化曲线	47
图 5-5	多模型间对比分析	48
图 5-6	LoRA 原理示意图	49
图 5-7	舆情分析中文语言模型准确率与损失值变化曲线	50
图 5-8	舆情分析中文语言模型与 BAG 模型对比图	50
图 5-9	舆情分析中文语言模型与 BAG 模型相似度变化图	51
图 6-1	银行业舆情数据采集与分析业务过程	53
图 6-2	功能模块结构图	55
图 6-3	用例图	55
图 6-4	舆情数据采集与分析系统业务架构	59
图 6-5	舆情数据采集与分析系统后台技术架构图	61
图 6-6	舆情数据采集与分析系统部署架构图	62
图 6-7	舆情数据采集功能系统时序关系	65
图 6-8	舆情数据处理流程图	66
图 6-9	舆情数据处理功能系统时序关系	67
图 6-10	舆情数据分析流程图	68
图 6-11	舆情数据分析功能系统时序关系	69
图 6-12	舆情数据加工功能系统时序关系	70
图 6-13	数据库 E-R 图	72
图 6-14	银行业舆情数据采集与分析系统首页	76
图 6-15	银行业舆情数据采集与分析系统配置中心页面	77
图 6-16	行业舆情数据采集与分析系统配置中心	77
图 6-17	银行业舆情数据采集与分析系统报告中心页面	78

表 格 目 录

表 2-1	LDA 模型中符号含义对照	14
表 3-1	数据集描述	23
表 3-2	种子词（部分）	25
表 3-3	金融领域银行专属情感词典（部分）	25
表 4-1	WHDP 模型符号含义对照	28
表 4-2	WHDP 模型因子图符号含义对照	30
表 4-3	WHDP 模型算法伪代码	32
表 4-4	WHDP 模型在数据集上采集到的主题下的词语	35
表 4-5	CHDP 模型因子图符号含义对照	37
表 4-6	CHDP 模型算法伪代码	39
表 4-7	CHDP 模型在数据集上采集到的主题下的词语	41
表 6-1	用户管理表（B_USER_MANAGE）	72
表 6-2	配置表（B_CONFIG）	73
表 6-3	数据采集任务表（B_COLLECT_TASK）	73
表 6-4	数据采集结果表（B_COLLECT_RESULT）	74
表 6-5	数据分析任务表（B_ANALYSIS_TASK）	74
表 6-6	数据分析结果表（B_ANALYSIS_RESULT）	75
表 6-7	数据报告表（B_DATA_REPORT）	75
表 6-8	采集配置功能的测试用例（部分）	79
表 6-9	采集任务配置功能的测试用例（部分）	80
表 6-9	采集任务配置功能的测试用例（部分）	81
表 6-10	舆情报告展示功能的测试用例（部分）	81

第一章 绪 论

1.1 论文研究背景及意义

1.1.1 研究背景

据官方数据显示,截至 2021 年底,我国全国共计开立 136.64 亿个银行账户,个人账户占据绝大比例,达到 135.81 亿户之多,同比增长 8.99%。在电子支付业务笔数上,同比增长 16.9%,高达 2749.69 亿笔,累计金额 2976.22 万亿元。随着银行账户的增加及支付、信贷等业务的不断增长,银行业越来越成为国家的经济命脉与强力支柱。而信用,是银行最大的可变现资产,在网络舆情这种新型社会舆情生态环境下,银行业的舆情风险管理工作面临着极大挑战,一旦掀起舆情风波,银行的信用受到冲击,后果不堪设想。轻则品牌名誉受损,重则引发金融风险。如发生在 2019 年,某商业银行被传倒闭,该传闻一爆出迅速引发民众挤兑事件,区区 4 天就发酵出相关新闻报道近 1370 多条,相关微博甚至是新闻报道的近 7 倍,可见舆情膨胀之迅速。哪怕后期对该舆情进行正面引导、地方政府使用信任背书、相关管理部门积极协调,保证客户存款正常支取,才平息了这场“闹剧”,但给民众的心理留下不可忽视的阴影与恐惧。又如 2020 年中国银行“原油宝”产品,由于中行移仓时撞上负价成交,这一极端巧合导致近 6 万名投资者穿仓亏损。这一系列事件也引发民众热议,中行的种种负面新闻和舆论都被发酵,严重影响银行品牌形象,降低客户信赖度。

正是因为银行业缺乏能根据自身业务经营需要来进行舆情文本数据采集与合适高效的文本情感分析模型,导致各类负面事件发生时没能第一时间控制舆论,从而失去了维持民众信心的黄金时间段;又导致没能及时给出解决方案,使用户失去投资意愿,流失大量用户。因此,面对外部舆情文本负面评价信息的风险,银行业亟需布局专属于自己的舆情数据采集与分析系统,提前做好舆情准备,正确处理危机。

1.1.2 研究意义

互联网规模扩大、飞速发展的时代，人人都手握“笔杆子”，这也导致舆情事件的层出不穷。大到国家、单位，小到个人，都时刻存在舆情风险。一直以来，国有大行都有很高的信誉度，但近年来银行业不断被曝出的“理财飞单”“存款消失”“被贷款、被办卡”“中国银行原油宝巨亏”“客户隐私泄露”“服务质量差”“不喝敬酒打员工耳光”“金融腐败”等负面事件，使得银行的声誉形象正在被一点点蚕食。若大家逐渐失去对银行的信任，不愿意存款或投资，社会会进入且长期处于低速发展状态。故银保监会于 2021 年 2 月 18 日制定并公布了相关办法——《银行保险机构声誉风险管理办法》，以进一步加强对银保机构的管理，有效化解银行保险机构品牌危机，持续防范银行保险机构声誉风险，稳定维护金融市场整体秩序，坚定广大民众信心，增强消费者对银行保险金融机构的信任。可见做好银行业舆情数据采集与分析工作，及时获取舆情数据、进行舆情分析，在维护社会稳定与保护银行品牌形象方面都有着极其重要的现实意义。

生成型预训练变换模型（chat Generative Pre-trained Transformer, chatGPT）的横空出世，将人工智能领域再一次推上浪潮之巅，也带来了无数令人遐想的空间。金融领域有着丰富的数据资源宝藏和可持续挖掘的数字化信息，如何让人工智能技术在这丰富的应用场景上发挥作用，赋能金融，提升效率，保障安全？目前国内外已有许多成熟的使用大数据、人工智能等新技术采集文本、分析文本的智能监测体系，但普遍都是应用于政府部门用于捕捉社会热点话题等。社会热点、商品评价等方面的舆情文本分析已然成熟，如何将这些领域的优秀理论在诸多专业化词汇限制的银行业进行实践？

本文立足银行业舆情数据采集与分析场景，考虑到银行业的特殊性——人们更倾向于通过财经类网站、新闻、官方发布的政策与文章等文本的方式获取相应信息，试图通过研究文本来发掘舆情文本关键内容与情感偏向，从而达到舆情分析、舆情监测、舆情预警的目的。由于银行业词汇的专业性与文本特点，目前缺少训练模型时统一的数据集与情感倾向判定的词典，本文首先构建了银行业专属的情感词典。再考虑到舆情文本的数据量，本文使用采样消息传递算法改进主题

模型，提升计算速度；采用 Bidirectional Encoder Representation from Transformers (BERT) 预训练模型作为词嵌入，提升训练速度。最后将改进后的主题模型与基于 BERT 的情感分析方法相结合在保证较高准确率的基础上提升效率。借助大数据先进技术，快速补齐人工分析的短板，加快推进智能化舆情数据采集与分析的平台和系统的建设，加强事前防范，推进事中引导，优化事后处理，提升银行的舆情控制能力、信息安全防范水平。

1.2 论文相关研究现状

1.2.1 银行业舆情数据采集应用现状

随着舆情文本信息数量的不断增长与发布渠道的不断扩散，对银行业舆情数据采集工作提出了更高的要求，舆情数据采集系统需要不断适应数据爆炸的现状，才能满足业务经营需要，做到高效地采集。目前市面上有很多舆情数据采集系统，也不乏对数据采集技术进行深入研究的公司^[48]。新浪舆情通就是这样一款智能软件，主要用于挖掘互联网中的舆情信息，并进行分类过滤，能有效地为政企单位提供实时的网络舆情信息；灯塔舆情监测和新寰舆情监测分析系统也是这样一类平台，可以全时全域、全覆盖、全自动地采集社会热点话题、突发事件、重大情报等。但近乎所有的产品都是通配地为企业、公司提供数据采集服务，更多的是关注社情民意，难以针对行业、内容进行个性化定制服务。

对于这方面的研究，国内也略迟于国外。例如美国就有较为成熟的网络舆情管理体系，其高级国防部研究过一套信息监测与跟踪系统，能利用关联方法监测检测舆情信息，且部分国外高校联动商业公司，积极落地最新的舆情数据采集成果，在实践中提升数据采集的质效。

据调研^[53]，对于舆情文本数据采集应用在银行业的情况，目前分为三个梯队：第三梯队中其内部缺乏舆情文本数据采集的技术人才，对舆情处理的系统资金投入不足。往往依靠人工的力量，通过一些浏览器或者搜索引擎依次输入相关的关键词来进行搜索，或依次浏览微博、财经类网站等公众网络平台的评论来了解大家的想法。有资金投入的第二梯队一般会选择鸿盾舆情通、识微、蚁坊软件舆情

系统等第三方平台来挖掘与追踪舆情动向，这类第三方平台可通过自定义目标关键词，以词组组合的形式监测，还可以自定义规则，能让银行的舆情工作人员更加快速精准的获取舆情数据。但是通过第三方平台来采集，涉及行业机密以及用户敏感信息等方面的舆情数据时则暗含风险。因此第一梯队着力于自主研发专属自己的舆情文本数据采集与分析系统，主要依托爬虫技术和自定义的规则对相关网站及关键词进行采集，再结合内部用户数据进行分析，安全性和准确性齐头并进。

本文所面对的问题便同第三梯队面对的问题相一致，要改变仍靠人工力量收集舆情风险的情况。改变各单位如遇舆情风险需填写风险台账，列明事件概要、风险类型等信息层层上报的问题。若过程流程繁琐，等到将舆情文本数据相关内容提交到处理部门，很可能已经错过了舆情处理的黄金时间，完全无法及时掌握舆情风向。

1.2.2 银行业舆情数据分析应用现状

同样，银行业舆情数据分析也分为三个层次：底部通常依靠人工对采集的数据进行分析，从数据采集到分析报告产出流程长、效率低、时效性不强。中部依托第三方平台的算法，可以快速分析舆情数据，能实现全天候全自动从年龄层次、发展趋势、地域特点等多维度产出报告，但第三方算法计算的结果过于刻板，分析报告形式规范但可参考性不高。因此头部着力于自研专属的算法，依靠数据挖掘、机器学习、深度学习等技术，在海量数据的训练与迭代优化调参下形成精准的分析模型与报告。

本文所遇到的问题也是还处在依靠人工给出舆情分析与处置方案的阶段，对层层上报的舆情文本内容给出风险研判、处置措施、应对口径，待各级部门审核完成后才形成真正的处理方案。在风险研判上有很强的个人主观色彩，在处置措施上也主要依靠分析人员的经验积累，整个流程复杂繁琐且缺乏数据支撑。

近年来，国内外有许多专家和学者对舆情数据分析进行了大量的理论方面的研究，比如目前已有一些基于深度学习的舆情分析应用的例子，可以凭借自动学

习特征弥补人力短板,就可以应用在银行业舆情数据采集与分析系统的设计与建立中。如周启航等人就探讨了海量网络舆情数据特征提取方面的问题^[71];如丁森华等人基于网络舆情数据着重比较了各种文本情感分析方法的效果^[39];如Fischer T 等人^[21]于 2018 年延伸拓展出的长短期记忆网络(Long Short Term Memory networks, LSTM),它克服了长期依赖方面的难题,预测准确性有了很大的提高;又比如 Sudipta Kar 等^[14]尝试把人工构建的词典单词代表、经过卷积神经网络(Convolutional Neural Network, CNN)处理后的特征以及通过双向门控循环单元(Bidirectional-Gate Recurrent Unit, Bi-GRU)处理后的特征三种相融合,提出用于分析舆情情感的新方法。这些基于深度学习的方法,很好地利用了机器自动学习特征的能力,克服了传统方法在处理大规模数据和复杂情感分析时的局限性。特别是在银行业舆情分析中,这些方法能够更准确高效及时地捕捉舆情重点、分析情感倾向、形成分析报告,尽早评估可能出现的风险,对银行业舆情控制有很大的现实意义,我们亟需这种方法的支持。

1.2.3 主题模型研究现状

在文本的舆情分析中对大量文本数据进行主题建模,提取文本中的主题信息,帮助分析师更好地理解舆论的热点,发掘潜在的问题便是主题模型的一大应用。

二十世纪以来,主流的主题模型有概率潜在语义分析(Probabilistic Latent Semantic Analysis, pLSA)^[8]方法。它是 Hofmann 等人提出的一种采用基于概率模型的最大期望值算法来训练潜在类的方法,假设文本是由两个隐变量组成的:文档主题和主题词,每篇文档都是由一些主题组成的,并且每个主题都有一些特定的词语。该方法能够得到一组主题-词语分布,可以用来对新文本进行主题分类。该方法的缺点是随着模型中文档数目的增加,参数的值会随之增加,存在过拟合问题,而且无法对未知数据集进行建模。为此 Blei 等人以此为依托,拓展延伸出潜在狄利克雷分配(Latent Dirichlet Allocation, LDA)模型^[1],它将狄利克雷(Dirichlet)参数引入到文档主题概率分布中,通过构建层次贝叶斯提升模型的泛化能力。该模型是建立在“词袋”假设的基础上的,这种模式就像把组成

文档的词语当做一个个小球，都丢到袋子中，打乱了词语间的顺序，导致单词间的语义混淆，因此对于这些方面的问题，该方法仍存在许多改进空间。曾嘉等^[27]于 2013 年将消息传递算法（Belief Propagation, BP）引入 LDA 模型，证明该算法比吉布斯采样（Gibbs sampling, GB）和变分贝叶斯（Variational Bayes, VB）在 LDA 模型中有更高的精度。但在具体应用中若采取上述方法，则需要用手工的方法确定最优聚类的个数，不切实际。因此 Teh 等提出了层次狄利克雷过程（Hierarchical Dirichlet Process, HDP）^[19]模型，但该模型也有无法直接进行采样的问题存在，为此在 2016 年王杰等^[59]人提出 HDP 采样消息传递算法模型。

同一时期，为了解决词语上下文关系的影响，常东亚等人给出了一种研究思路：用窗口保留词语的上下文关系，将窗口进行滑动来保证局部顺序性。这种方法被称之为“滑动窗口”，基于该思路与方法，他们研究出了基于滑动窗口的主题模型^[32]（Sliding-Window based Topic Model, SWTm），提升了泛化能力和精度。2 年后，他们通过进一步研究，给出了一种新的研究思路——以中心词为基准，将其前后文中一定范围内的数个词的相关信息纳入主题概率分布的计算。基于这种思想，他们提出了基于中心词上下文的主题模型^[33]（Centroid-word based Contextual Topic Model, CCTM）。这两种新颖的思路与方法为我们的研究提供了研究方向和新的可能：他们都是基于主题模型，计算量庞大，本文试图寻找一种求解方法能够优化求解过程，提升模型的计算速度。

1.2.4 情感分析研究现状

在自然语言处理领域的研究中，情感分析占据了重要的一席之地，下面介绍几种经典的情感分析方法。

LSTM^[7]通常把单个句子看作一个序列数据，通过训练获得句子向量，其中包含句子上下文的语义。还构思巧妙地利用特殊“门”的结构对原始循环神经网络（Recurrent Neural Networks, RNN）模型进行完善，控制向单元进行增删的信息，模型中每个 cell 的内部构造复杂，如图 1-1 所示，却能高效应对 RNN 模型中出现的问题——梯度爆炸和梯度消失。




图 1-1 LSTM 结构

Cho 等^[15]人在 LSTM 的基础上研究出了一种变种方法:门控循环单元(Gated Recurrent Unit, GRU),这也是最有特点极具代表性的一种,引入了“更新门(update gate)”与“重置门(reset gate)”的概念。GRU 的单元结构如下图 1-2 所示:




图 1-2 GRU 单元

为了解决 LSTM 对句子建模时依赖于对语义信息编码从前到后的方向性,又提出了一种由前向 LSTM 和后向 LSTM 共同组成的、称之为双向长短时记忆循环神经网络^[13] (Bi-directional Long Short-Term Memory, Bi-LSTM) 的模型。比起标准 RNN 和 LSTM, 双向 LSTM 可以让 Bi-LSTM 可以更好地从句子中抽取关键信息。

深层金字塔卷积神经网络^[11] (Deep Pyramid Convolutional Neural Networks, DPCNN) 主要由 Repeat 结构、卷积块 (Block) 和区域嵌入层 (Region embedding) 三部分结构组成, 其中特别要提到区域嵌入层中使用了等长卷积, 这是 DPCNN 不同于基于 CNN 的文本分类模型 (Text Convolutional Neural Network, TextCNN)

的一大特点。这意味着某个词进行等长卷积后嵌入层会在该词的上下文中添加一个窗口，以该词为中心，且大小为 n 。这样，可以大幅增加卷积核能感知到的文本片段，在长距离的语义关系表示上更友好，最大限度的学习更多全局信息。DPCNN 的思想是让高效的卷积层和低效的分类层互相补偿，让卷积层承担部分分类层的工作，且利用残差连接（Residual Connection），将区域嵌入层的输出与每个卷积块的输入相连接，使模型以接近 TextCNN 水平的速度起步，缓解了梯度消失的问题，节约计算时间。但考虑到算力的限制，我们不能无限扩展神经网络隐含层层数，也无法无止尽地增加神经单元个数。因此，人们提出了许多方法对神经网络进行简化，试图在模型复杂度高低和表达能力强弱之间找到一个平衡点，如权重共享（将训练数据的特征权重分配给多个模型）、局部连接（融合不同模型间的信息）以及池化（将训练数据的特征值集中在某个区域）等优化操作企图降低模型的复杂度，提升模型的表达能力。哪怕是这样，很多会使模型效果下降的问题依然存在，例如 CNN 中的长程依赖等。为此，又引入了注意力机制^[5]（Attention）——这种机制的灵感来源于人脑，因为人类在获取大量信息时通常会抓重要部分或者抓重要部分主要方面。

于是，Vaswani 等人更上一层楼，提出了一种采用自注意力（Self-attention）机制的叫做 Transformer^[70]的全新网络架构，可以将不同位置的相同序列自我关联。利用堆叠的 Self-attention 层和全连接网络构建编码器（Encoder）和解码器（Decoder），更有效地提取特征。残差连接（Residual Connection）^[2]使得模型可以更加关注层间差异的部分。基于这种新的网络架构，能很好地提取文本特征进行情感分析。

1.3 论文主要内容与贡献

1.3.1 论文主要内容

商业银行及时对舆情文本数据进行采集与分析，可及时发现舆情，获得主动权，辅助银行内部人员做出重要决策；可尽快控制舆情，掌握主导权，维持市场稳定与经济持续发展。但根据实际调研情况，首先，目前数据铺天盖地，银行业

缺少能从海量文本信息中获取、筛选、提炼关键要素的技术，没有数据的支撑，单凭人力难以做出合适有效的决策；其次，在银行业相关的舆情文本上的分类需要有更准确的方法，情感分析需要有更专业、覆盖面更广泛的情感词典。当前使用的分析方法受经验影响且带有很强的主观色彩，未经过足够的时间与数据的验证，在各方面仍有许多可以提升的空间。本文主要针对上述调研发现的问题进行研究，研究内容如下：

1. 构建金融领域银行专业情感词典。由于银行领域的专业性、特殊性，一些常用的情感词典并不适配银行业相关的舆情文本的情感分析。因此本文通过人工+自动的方法构建专属金融领域的银行专业情感词典，基于该词典进行情感分析能提高舆情分析的准确率。

2. 提出基于窗口改进的 HDP 采样消息算法和基于中心词改进的 HDP 采样消息算法。传统的 HDP 采样消息算法存在语义混淆与忽略上下文影响的问题，本文尝试利用窗口将文档切割成更细碎的片段，用窗口保留词语的顺序性，降低文本语义上混淆的可能性。还尝试将一个词作为中心，使用窗口将前后若干词纳入范围，保留上下文语义信息。计算该词的主题概率，同一个词语在不同位置的情况均不相同，借此方法保证局部语义的正确性。

3. 结合改进的主题模型与基于 BERT 的情感分析算法以及构建的银行专业情感词典来对采集的相关舆情数据进行分析，并对大模型如何应用在舆情分析领域进行探索。

4. 设计并实现一个银行业普适的稳定的舆情数据采集与分析系统。可将舆情相关的信息，例如原始数据、分析表格等以直观的方式呈现，便于银行业舆情管理人员分析并制定策略，维护品牌形象，保证金融市场的稳定。

1.3.2 贡献

针对商业银行通过人力进行舆情分析存在信息茧房、时效性差、主观色彩强等问题，缺少智能辅助分析系统以及进行舆情情感分析缺少专业模型以及专业情感词典支撑等痛点，本文贡献如下：

1. 使用 Scrapy 爬虫框架爬取金融网站银行板块数据，构建本文实验的数据集以及金融领域银行专业情感词典。
2. 使用采样消息传递算法改进 HDP 模型，提出基于滑动窗口的 HDP 采样消息传递算法模型和基于中心词的 HDP 采样消息传递算法模型。
3. 结合改进的主题模型和基于情感词典以及预训练模型的情感分析算法对采集的数据进行分析。
4. 设计并实现一个银行业普适的稳定的舆情数据采集与分析系统。

1.4 论文组织结构

第一章 绪论。阐明本文研究的现实背景及研究的实际意义、罗列国内外相关研究的现状、研究的主要内容以及主要工作与贡献，阐述本文的具体结构。

第二章 相关理论与知识研究。关键是通过介绍舆情数据采集相关技术、舆情数据分析相关技术、系统设计与实现相关技术来说明本文选择这些技术的原因以及针对这些技术的缺点进行改进与优化的方向与方法。

第三章 构建舆情分析模型。展示舆情文本数据采集与分析流程中算法部分的框架，介绍本文选取的 3 种关键算法，并说明针对相应的缺点进行改进的思路，构建舆情分析模型以及本文的金融领域银行专属情感词典。

第四章 构建主题模型。分别阐述基于窗口和基于中心词的 HDP 采样消息传递算法模型的基本原理，给出了因子图并据其详细描述了模型的近似推理过程与算法的伪代码，并且通过对比实验确认了改进的合理性，构建主题模型。

第五章 构建情感分析模型。通过比对基于情感词典、基于预训练模型、基于大模型的舆情文本情感分析方法，分析三种方法的效果与局限性，选择出高效适配的情感分析方法，能够更好地对文本语义进行理解，构建情感分析模型。

第六章 系统的设计与实现。梳理本系统主要的功能需求以及业务流程，分析探讨系统的非功能性需求。通过划分功能模块并进行用例分析，完善系统框架，阐明整体设计思路。从业务、技术、功能、数据等四个方面阐述系统设计的整体思路。并以此为据搭建合理的平台框架，组装合适的应用功能，建造可靠的数据

基底。展示系统核心模块的具体应用效果，体现本系统开发实现的成果。列明对本系统进行测试的方法与案例，经过多维度多轮测试，给出本系统测试结果。

总结与展望 是对本文整体工作的总结和对未来规划的展望。

第二章 相关理论与知识研究

2.1 舆情数据采集相关技术

舆情数据采集技术是指通过对网络各类信息（贴吧、论坛、网页等平台）进行大量自动化的收集和获取，且利用相关的要素来筛选数据并保留有效数据。在众多数据采集方法中，网络爬虫相比较而言是简单且较为成熟的技术，主要用于采集获取互联网（World Wide Web，web）站点的数据。

本文使用 Scrapy 框架^[57]，该框架非常成熟，广泛应用在数据挖掘领域。使用该框架，我们可以根据自己的需求修改调度器，定制自己的爬虫，可以对指定的 web 站点进行快速高效抓取，主要由图 2-1 中方框中的五大组件组成。本文主要基于 Python 来使用该框架编写爬虫，用于抓取凤凰财经、财经网、天天基金等金融领域相关 web 站点银行板块的内容，并将结构化数据从页面中提取出来。

如图 2-1 所示，为 Scrapy 框架的工作流程。




图 2-1 网络爬虫工作流程示意图

2.2 舆情数据分析相关技术

用适当的方法对采集到的海量舆情数据进行汇总、清理、分类、提取有用信息、形成结论，使数据的内涵得到最大程度的发挥，从而进行详细的研究，进而得出有用的结论。在这里我们设计使用主题模型对舆情文本进行主题提取与分类，

然后使用情感分析算法分析文本的情感倾向,通过两种方法相结合对舆情文本进行分析数据。

2.2.1 HDP 模型

由于银行业相关的舆情文本长短不一且涉及范围广,可能有关某个产品,可能有关某个政策,也可能有关某个新闻事件,甚至这些要素之间还存在关联关系。因此,在主题模型的选择上,我们需要一个能够自动确定主题个数且可以有效处理词频较低词汇的模型。我们选择了分层狄利克雷过程(Hierarchical Dirichlet Process, HDP)模型^[19]。该模型具体结构如图 2-2 所示,这一个无参化的、能自动确定主题个数的三层贝叶斯模型,解决了狄利克雷过程只能分析一组数据的聚类问题的情况。




图 2-2 HDP 模型图

根据上述狄利克雷(Dirichlet Process, DP)过程的公式,可以知道从以 γ 为超参数、 H 为基分布的 DP 过程可以计算出总体主题分布 $G_0 \sim DP(\gamma, H)$ ^[41]; 接

着，计算每篇文档的主题分布可以以 α_0 为聚集参数、 G_0 为基分布得到 $G_j \sim DP(\alpha_0, G_0)^{[31]}$ ，其中 $j \in [1, 2, \dots, D]$ ；然后从主题分布 G_j 中生成一个主题 $\theta_{ji} \sim G_j$ ；最后，用 w_{ji} 表示文档 j 的第 i 个单词，在给定主题 θ_{ji} 时，观测变量 w_{ji} 的分布用 $F(\theta_{ji})$ 表示，可以从主题单词分布 $F(\theta_{ji})$ 中生成单词 $w_{ji} \sim F(\theta_{ji})$ 。

基于 HDP 模型我们能动态增删主题，保持整体主题一致性，组织不同文档间主题的共享，但是也存在计算量大的缺点。

2.2.2 消息传递算法

为了克服 HDP 模型计算量大的问题，我们引入了消息传递算法。该算法一般用于求解随机变量在给定的依赖条件下的概率，且在主题模型上有过应用——首次应用是曾嘉等^[27]人的团队进行的。他们使用这种算法对 LDA 模型进行求解，很大程度上减少了计算量，将原本复杂的 LDA 模型图分解转换为等价的更简单更易于处理的因子图，也就是将一个多因子的全局函数等价拆分替换成多个局部函数之积^[17]。同样的，这种思路可以帮助我们降低 HDP 模型的计算量。

对于该算法求解 LDA 模型中使用到的公式中符号含义对照如表 2-1：

表 2-1 LDA 模型中符号含义对照

符号	含义
d	当前文档
w	当前单词
$\mu_{w,d}(k)$	d 中 w 的主题概率（是各因子的概率之积）
$\mu_{-w,d}(k)$	d 中除 w 外的其他所有单词的主题概率
$\mu_{w,-d}(k)$	除 d 外的所有 w 的主题概率
$\mu_{.,d}(k)$	d 中所有单词的主题概率
$\mu_{w,.}(k)$	所有文档中 w 的主题概率
$x_{-w,d}$	d 中除 w 外其他单词的数目
$x_{w,-d}$	除 d 外其他文档中 w 的数目

这些参数的更新迭代公式如下式（2-1）、式（2-2）式（2-3）所示：

$$\mu_{w,d}(k) \propto \frac{\mu_{-w,d}(k)+\alpha}{\sum_k [\mu_{-w,d}(k)+\alpha]} \frac{\mu_{w,-d}(k)+\beta}{\sum_w [\mu_{w,-d}(k)+\beta]} \quad (2-1)$$

$$\mu_{-w,d}(k) = \sum_{-w} x_{-w,d} \mu_{-w,d}(k) \quad (2-2)$$

$$\mu_{w,-d}(k) = \sum_{-d} x_{w,-d} \mu_{w,-d}(k) \quad (2-3)$$

通过推导，最后得到 φ_w 、 θ_d 的更新公式如式（2-4）、式（2-5）。

$$\theta_d(k) = \frac{\mu_{.,d}(k)+\alpha}{\sum_k [\mu_{.,d}(k)+\alpha]} \quad (2-4)$$

$$\varphi_w(k) = \frac{\mu_{w,.}(k)+\beta}{\sum_w [\mu_{w,.}(k)+\beta]} \quad (2-5)$$

2.2.3 情感分析技术

对于舆情分析来说，很重要的一点就是情感分析——分析出该舆情是正面的还是负面的。正向舆情一般不需要过多干预，任其自然发展即可；负向舆情则需要分门别类，再根据具体的舆情内容使用不同的舆情控制方法。对于银行业相关的文本的情感分析，还有一大难点就是行业词汇专业性。因此，我们首先需要构建一个专属于金融领域的银行专属情感词典，然后基于该词典进行情感分析算法的实验。

众多文本的情感分类方法中有一种是基于情感词典的情感分类方法，该方法的主要流程如图 2-3 所示，首先对获取的舆情文本进行清洗，去除冗余和无效部分，再进行分词处理，接着从中筛选情感词，将其与预先建立的情感词典进行比对，累加情感得分，最终计算出该文本的情感倾向。



图 2-3 基于情感词典的文本情感分类方法

但该方法仍然存在很多提升空间，首先中华文化博大精深，能表达情感的词语数不胜数，情感词典无法囊括所有词语及其情感倾向；接着当情感词典中没有该词时只能通过其他方法间接计算该词的情感得分。采用简单的间接计算方法，

可以将与该词最相似的词语的情感值乘以两者的相似度，如图 2-4 所示。




图 2-4 文本情感值计算流程

此外，程度副词、表达否定意思的词、标点符号（如省略号、感叹号）等暗含情感的元素也影响着文本的情感倾向。如“好”、“很好”、“非常好”、“不好才怪”、“好？”，“烂”、“好烂”、“烂炸了”。这些例子每个所诠释出的情感程度都大不相同，一个标点符号之差，所表达的意思就有着天壤之别。这些因素都影响着最终的情感得分，都需要被考虑在内。

2.2.4 文本分类技术

在文本分类过程中，一般采用特征矢量的形式来表示文档。举个最常见的模型为例，在词袋（Bag-of-words）模型中，将文档集中所有出现的词组成一个特征空间，其中每一维都表示一个特征，因此文档集中出现的不同词的个数就决定了该特征空间的维度。每个文档集都可以转化为一个词-文档矩阵，具体一篇文档 D_i 表示如下式（2-6），其中 d_{ij} 表示被索引的第 j 个词的权重。

$$D_i = (d_{i1}, d_{i2}, \dots, d_{in}) \quad (2-6)$$

可见哪怕在一个极小的文档集中，特征数量也就是不同词的个数都很多。如

果是一个较大的文档集合，它的特征空间维度可见一斑，哪怕特征向量很稀疏，却因存在大量不为 0 的特征而无法缩略。

从一组特征集中选择所需的特征子集的过程叫做特征选择，需要针对目标任务，考虑特征子集与目标任务的相关性，选择出的特征既不能是无关的（指该特征必须在一定程度上影响文本分类的结果），同时这个特征也不能是冗余的（指该特征必须要提供部分新的信息）。在传统长文本分类中，文本预处理的重要步骤之一就是特征选择，这一步骤很大程度上影响了文本分类的效率与结果，需要去除大部分无关或者冗余的词，特别是停用词。

2.3 系统设计与实现相关技术

本系统采用当下主流的 Java 语言进行开发，使用 Python 语言编写爬虫以及训练数据，采用 Web 网页的展示方式与用户进行交互，使用 DB2 数据库存储相关数据。

2.3.1 Web 开发框架

React 框架是一种高效的开发工具，特别是擅长处理组件化页面的特性使它能有效应对开发数据与日俱增的大型应用程序。它可移植性强，能够与任何库集成而不必依赖于任何库，因此一般被用来作为模式-视图-控制器设计模式（Model-View-controller, MVC）中的视图层。它兼容性好，语法是 JSX，最大程度简化了组件的创建，故混用 JS 和 HTML 编写也不在话下，既能在浏览器端运行，也能在服务端渲染。它性能强大，将部分服务器的功能转移到了客户端，克服了交互类操作必须依赖服务器的问题，减轻服务器压力。

2.3.2 Spring 框架

选择 Spring 框架作为企业应用开发的基层架构是由于其层次化与轻量级这两个主要优点，且同时可以集成其他不同框架。高内聚、低耦合的编程方式，直接面向接口，便于业务逻辑的处理、简化数据库的访问，利于快速迭代和协作开

发，显著降低开发成本^[42]。

2.3.3 DB2 数据库

DB2 有极强的的可伸缩性，适用范围广，大可支撑大规模的应用操作系统，小可到单用户环境。DB2 的数据分级技术可以很容易地将大型机上的数据下载到本地，提供便利的方式让用户对数据进行访问。它还支持多任务并发查询，可同步启动上千个活动线程，大大提高系统的处理能力，可以更快地响应用户的请求，保证系统运行平稳。虽然，DB2 数据库有很好的数据安全性，不过在信创项目的逐步推进下，我们将逐步迁移到 OceanBase 数据库。

2.3.4 Java 开发语言

Java 语言可以让多个平台同时为其提供语言支持，这也表示了其具有较强的语言移植性。Java 语言在操作系统上运行时，不仅具有良好的性能，同时也不需要重新编译和底层改动，对当前主流的五大操作系统更是能够全面支持。这意味着用户可以使用多种类型的智能终端经由网络访问和使用该语言编写的管理系统。

Java 语言有面向对象、简单易掌握、可移植、多线程的特性。封装可以将某些实体所具备的属性以及方法合并，使用时，只需要对该类中的该实体进行声明即可。继承机制和多态使得代码可复用性提高。

2.3.5 Python 开发语言

Python 语言是一种面向对象开发的动态语言，在近几年有十分广泛的应用场景，其具备十分强大的标准库，可供用户使用时根据自己的需求来进行调用。Python 语言现今已应用至计算机的多个领域。Python 有 2 和 3 的版本，本文基于程序的灵活性和编写的方便，选择了使用 Python 3.7.4 作为主要的编程语言。其中大部分的模块都是以插件式地进行编写，每个模块都可以单独拿出来使用，并且可以继续增加新的模块进去。

2.3.6 JIEBA 分词工具

本系统使用的中文分词工具为 JIEBA，它提供了多种分词模式，可以基于词库，使用词频-逆文档频率 (Term Frequency - Inverse Document Frequency, TF-IDF) 算法确定汉字间的关联概率，将有序的汉字序列分割成有意义的词语，形成分词结果。其中文分词和词性标注功能是本文中使用到的频率很高、很重要的部分。

通过该工具可以对初步爬取的信息进行处理，得到关键词及权重后再发起新一轮的信息爬取，两者相结合而提升爬虫爬取相关内容的准确度。且通过关键词提升文本分类的精度。

第三章 构建银行业舆情分析模型

本章主要介绍本文进行银行业舆情文本数据采集与分析流程的整个过程中构建的舆情分析模型的以及使用到算法的部分，展示了流程框架中算法的选择以及选择思路。

3.1 模型设计框架




图 3-1 银行业舆情分析模型设计框架图

银行业舆情文本数据采集与分析算法整体设计框架如图 3-1 所示。

首先是数据采集部分，以基于自定义采集规则的网络爬虫为抓手进行数据采集，通过自定义采集规则可以指定采集的范围、解析格式以及采集频率等一系列参数，更具个性化，随后使用 JIEBA 分词工具进行初步处理。

然后是主题模型部分，使用主题模型进行主题提取、主题聚类、形成关键词等。但使用 HDP 模型虽然能动态增删主题，保持整体主题一致性，组织不同文档间主题的共享，却还存在计算量大的缺点。因此借鉴了曾嘉团队的思路，使用消息传递算法求解 HDP 模型，将原本复杂的 HDP 模型图分解转换为等价的更简单更易于处理的因子图，也就是将一个多因子的全局函数等价拆分替换成多个局部函数之积，降低 HDP 模型的计算量。同时，借鉴常东亚团队的想法，通过引入滑动窗口和中心词两种概念改进 HDP 模型。滑动窗口，使文档能被细分成更小的片段并保证了局部词间的顺序性，保留附近单词对主题词的影响。中心词，以该词为中心纳入上下文环境的语义信息，保留了单词涉及到的所有主题信息。从而提升主题模型的泛化能力和准确率。此外，结合上述步骤提取的关键词和常见的情感词典，构建金融领域银行业专属情感词典，作为本文算法中情感分析部分的计算标准。

接着是情感分析部分，通过情感分析计算文档的情感倾向性。最简单的做法就是基于本文所构建的专属情感词典进行情感值的计算，但该方法具有很强的不确定性，结果准确率会因情感词典的变化而产生大幅波动。因此，最终通过实验对比，选择情感分析领域常见的基于预训练模型以及基于大模型的两种分析算法做文本的情感分析。

3.2 构建专属情感词典

针对文本的情感分析，可以将其划分为三个逐步递进的层次：词级别、句子与文档级别、目标级别。其中词级别是研究如何判定某个词语的情感信息，句子与文档级是研究如何标注句子或文档的情感标签，对于目标级则是分析文本中出现的实体、实体属性、实体与属性。当前研究中，我们通常只考虑情感分析五要

素（如图 3-2 所示）中的对象和观点。




图 3-2 情感分析五要素

基础情感词典具有普适性，但在实际应用中，不同领域的情感分析很难基于基础情感词典进行，实际分析效果较差，不够理想。要想提升银行业舆情文本的情感分析准确率，我们必须在情感词典的基础上蒸馏出专属情感词典。因此，本文采取情感倾向点互信息算法（Sentiment Orientation-Point Mutual Information, SO-PMI）自动构建情感词典，再加之人工标注的人工词典与基础情感词典，三者结合，形成一个专属应用于银行领域的银行领域情感词典^[60]。银行领域情感词典的组成部分如下图 3-3 所示。




图 3-3 银行领域情感词典构成

采取如下步骤构成银行领域情感词典：

（1）处理爬虫采集的舆情文本数据

如图 3-4 所示为本文设计的爬虫从金融网站银行板块爬取内容的示例，主要

图 3-4 爬虫采集的舆情文本数据示例

应用 JIEBA 分词工具对文本数据进行预处理、特征化。向量特征化后的数据集具体信息如表 3-1 所示。

数据集	单词表大小 W	文档总数 D	非 0 元素个数 NNZ
银行舆情数据集	1607298	196085	760590

点互信息^[24]（Point Mutual Information, PMI）常用来衡量两个事物的关联性，本实验中我们使用该方法来判断两个词语的关联性，两个词语关联性越强，PMI 的值也会相应越大，这意味着同时出现的概率越大，如图 3-5 所示为 PMI 值的大小所对应的词语关联性。

计算 PMI 值的公式可见式 (3-1)，其中， $p(word1)$ ， $p(word2)$ 两个参数分别表示单词 $word\ 1$ 和单词 $word\ 2$ 单独出现的概率大小，而参数 $p(word1, word2)$ 则表示单词 $word\ 1$ 和单词 $word\ 2$ 同时出现的概率^[67]。

23




图 3-5 PMI 结果示意图

SO-PMI 算法^[24], 常用来衡量某个词语的情感倾向性, 是 Turmey 在 PMI 计算思路的基础上提出的, 可以计算词语的情感倾向, 判断词语的情感极性。首先, 在基准词的选择上, 优先选出情感极性的一组正向词和负向词, 分别表示为负向种子词 $Nwords$ 和正向种子词 $Pwords$ ^[31]。

当要计算某个未知词 $word$ 的情感倾向时, 分别计算其与 $Nword$ 和 $Pword$ 的 PMI 差值, 通过差值可以得出结论, 如图 3-6 所示为 SO-PMI 值的大小所表示的词语情感极性结果。其计算公式如下式 (3-2) 所示。

$$SO - PMI(word) = \sum_{Nword \in Nwords} PMI(word, Nword) - \sum_{Pword \in Pwords} PMI(word, Pword) \quad (3-2)$$




图 3-6 SO-PMI 结果示意图

(3) 基础情感词典构建

本文选取几个常见的比较经典的情感词典作为基础, 分别是台湾大学简体中文情感极性词典 (NTUSD)、知网词典 (HowNet)、褒贬义词典、大连理工大学情感词典, 基于这些词典, 我们进行了拆分、重组、重构的工作, 从而形成一个全新的基础情感词典。

首先对 HowNet 词典进行处理。该词典收纳的是中文词典中的常识知识, 需要去除其中鲜少使用的生僻字。接着处理大连理工情感词典中的内容, 去除情感极性不明显的词汇然后分别按照情感极性将上述两个词典剩余的词汇加入到对应的情感词典。再将 NTUSD 和褒贬义词典中的词按褒贬义分别添加到对应的情感词典。最后对整体进行去重与整理。

通过这一系列流程, 将上述四个情感词典拆分重组成一个基础情感词典, 其

中包含了积极和消极两大类词汇，供本文后续构建金融领域银行专业情感词典的使用。

（4）金融领域银行专业情感词典构建

本文以凤凰财经、财经网、天天基金等网站的银行板块为数据源，抓取相关文本作为语料，经过 JIEBA 分词的预处理操作后，按词频高低排序筛选出前 1000 个词汇，去除词频过低的（此处设定小于 5 的情况）词汇，经由一百位人工标注者进行手动处理，去掉明确的非相关词汇，并对剩余词汇做最后的复核，最终将大家达成共识的标注结果相同的词汇作为种子词。最终得到的种子词（部分）如下表 3-2 所示。

表 3-2 种子词（部分）

情感极性	种子词
积极种子词	稳定、走高、涨停、涨幅、拉高、安全、红、调整、高涨、扭转、抢、反弹、高涨、扭转、祥和、支撑、阳、赤、长阳、翻红、光明
消极种子词	降、跌、暴雷、空仓、约谈、欺诈、低、减持、看跌、空头、破产、下行、负债、灰暗、危险、悬

接着将这些种子词与基础情感词典进行比对，若不在其中则计算该词与种子词的 SO-PMI 值。按 SO-PMI 值的计算结果判断需要归入哪一类情感词典。经过上述步骤的操作后，最终通过人工进行收口，保证构建的情感词典的准确性。

自动构建得到的情感词典有 1324 个消极情感词汇、1218 个积极情感词汇，将基础情感词典和构建出的情感词典合成金融领域银行专属情感词典，最终该情感词典的规模为 1837 个消极情感词汇和 1689 个积极情感词汇。如下表 3-3 展示了其中部分较有代表性的词汇。

表 3-3 金融领域银行专属情感词典（部分）

情感极性	词汇
积极情感词	稳定、走高、涨停、涨幅、增幅、牛、加息、回弹、应收、利好、盈余、增值、增长、追上、拉高、安全、红、爆、抢、反弹、领先、收益、推荐、增收、飚高、加仓、拉满、转入、看涨、普惠、安利、种草、活跃、调整、高涨、扭转、复利、增收、祥和、支撑、冲

续表 3-3 金融领域银行专属情感词典（部分）

情感极性	词汇
消极情感词	降、跌、暴雷、空仓、止损、亏本、亏、冻结、跌停、撤退、退出、挤兑、抛售、反对、投诉、违规、赔偿、低、减持、看跌、熊、缩水、空头、破产、下行、负债、绿、破产、赤字、虚、泡沫、缩水、下调、透支、失信、呆账、罚款、崩盘、洗钱、赤字、约谈、欺诈

第四章 构建主题模型

本文使用主题模型进行主题提取、主题聚类、形成关键词等操作，但使用 HDP 模型存在计算量大的缺点。因此借鉴了曾嘉团队的思路，使用消息传递算法求解 HDP 模型，降低 HDP 模型的计算量。同时，借鉴常东亚团队的想法，通过引入滑动窗口和中心词两种概念改进 HDP 模型，提升主题模型的泛化能力和准确率。本章主要介绍基于窗口的 HDP 采样消息传递模型（Window-based Hierarchical Dirichlet Process, WHDP）与基于中心词的 HDP 采样消息传递模型（Centroid-word based Hierarchical Dirichlet Process, CHDP），阐述其主要原理，分析因子图模型，推导计算过程，给出算法的伪代码实现以及多个模型对比实验的结果与分析。

4.1 基于窗口的 HDP 采样消息传递模型

4.1.1 WHDP 采样消息传递模型

HDP 模型未考虑词语之间的关联，他的近似推理过程中基本上使用如下两种算法：吉布斯采样（Gibbs sampling）^[1]，计算过程中采用迭代的方式，收敛速度慢^[59]；变分法（Calculus of Variations），虽收敛速度快，但每次迭代耗费在计算时间复杂度上的资源占比巨大。故本章提出了一个基于窗口的 HDP 采样消息传递模型（WHDP）。其核心思想在于：结合消息传递算法进行近似推理，提升模型的收敛速度。通过设定窗口大小来限制文档划分的粒度，使其能被切割成较小的片段；同时，窗口的存在也保证局部词间的顺序性，保留附近单词对主题词的影响。




图 4-1 WHDP 采样消息传递模型

图 4-1 可以清楚看到 WHDP 采样消息传递模型的推导过程，具体各参数的含义可以见表 4-1。

表 4-1 WHDP 模型符号含义对照

符号	含义
α	聚集参数
β	聚集参数
γ	聚集参数
z	主题
d	当前文档
D	所有文档的总数

续表 4-1 WHDP 模型符号含义对照

符号	含义
s	d 中的任意一个窗口
S	d 中的窗口的总数
N	每个窗口中单词数量的总数
$z_{s,i}^d$	每个文档 d 中的窗口 s 中单词的主题
$w_{s,i}^d$	本模型的变量部分，可动态调整，表示 d 中的窗口 s 中的第 i 个单词
$\theta_{s,d}$	d 中第 s 个窗口的主题分布，其中 $s \in [1, 2, \dots, S]$
φ_k	第 k 个主题的单词概率分布

4.1.2 WHDP 采样消息传递模型的近似推理方法




图 4-2 WHDP 采样消息传递模型因子图

图 4-2 表示的是 WHDP 采样消息传递模型因子图，其计算关键就是一篇文档中单词的主题同时受该单词在不同窗口的主题和同一窗口个中不同单词的主题影响。具体各参数的含义可以见表 4-2。

表 4-2 WHDP 模型因子图符号含义对照

符号	含义
α	聚集参数
β	聚集参数
γ	聚集参数
z	主题
d	当前文档
D	所有文档的总数
s	d 中的任意一个窗口
S	d 中的窗口的总数
N	每个窗口中单词数量的总数
W	所有文档不同词语的数量
$z_{-w,s}^d$	d 的 s 中除了单词 w 以外所有单词的主题
$z_{w,-s}^d$	除 s 以外的其他窗口中单词 w 的主题
θ_d	d 关于主题的因子
φ_w	w 关于主题的因子
$x_{w,-s}^d$	除 s 外其它窗口中的单词 w 的总数
$x_{-w,s}^d$	s 中的除了单词 w 外其它单词的总数
$x_{w,-s}^d \mu_{w,-s}^d(k)$	d 中当前窗口的单词 w 的主题受该单词在其他窗口的主题的影响
$x_{-w,s}^d \mu_{w,-s}^d(k)$	同一窗口不同单词的主题的影响
$\mu_{w,s}^d(k)$	d 窗口 s 中每个单词的主题概率

根据消息传递算法^[59]可推出单词中已发现的 K 个主题的概率，表示如下式 (4-1)，其中 $k = 1, \dots, K$ ：

$$\mu_{w,s}^d(k) \propto \frac{\sum_s \mu_{w,s}^d(k) + \alpha \tau(k)}{\sum_k [\sum_s \mu_{w,s}^d(k) + \alpha \tau(k)]} \frac{\mu_{w,s}^d(k) + \beta}{\sum_w \mu_{w,s}^d(k) + \beta} \quad (4-1)$$

尚未发现的主题 $K+1$ 的概率可以根据 CRF 构造^[19]获得，表示如下式 (4-2)：

$$\mu_{w,s}^d(K+1) \propto \frac{\alpha \tau(K+1)}{W} \quad (4-2)$$

$\mu_{w,s}^d(k)$ 和 $\mu_{w,-s}^d(k)$ 的迭代更新公式如下式 (4-3)、式 (4-4)：

$$\mu_{w,s}^d(k) = \sum_{-w} x_{-w,s}^d \mu_{-w,s}^d(k) \quad (4-3)$$

$$\mu_{w,-s}^d(k) = \sum_{-s} x_{w,-s}^d \mu_{w,-s}^d(k) \quad (4-4)$$

狄利克雷过程先验 τ ，如下式 (4-5)、式 (4-6)：

$$\tau(k) = \frac{\pi_k^{(1)}}{\pi_k^{(2)}} \prod_{l=1}^K \frac{\pi_l^{(2)}}{\pi_l^{(1)} + \pi_l^{(2)}} \quad (4-5)$$

$$\tau(K+1) = 1 - \sum_{k=1}^K \tau(k) \quad (4-6)$$

其中 $\pi_k^{(1)}$ 与 $\pi_k^{(2)}$ 计算如下式 (4-7)、式 (4-8)：

$$\pi_k^{(1)} = 1 + \sum_{s=1}^W \sum_{w=1}^C \mu_{w,s}^d(k) x_{w,s}^d \quad (4-7)$$

$$\pi_k^{(2)} = \gamma + \sum_{s=1}^W \sum_{w=1}^C \sum_{t=k+1}^K \mu_{w,s}^d(k) x_{w,s}^d \quad (4-8)$$

可推算得文档 d 的主题分布 θ_d 和主题单词分布 φ_w 的迭代更新公式，以及文档的主题 z_d 见式 (4-9)、式 (4-10)、式 (4-11)，其中当 $z_d = k$ 时， $\delta(z_d, k) = 1$ 其余情况其取值均为 0。若当前单词主题未发现时，则需要更新迭代相关参数。

$$\theta_d(k) = \frac{\sum_s [\mu_{w,s}^d(k) + \mu_{w,-s}^d(k)] + \alpha \tau(k)}{\sum_k [\sum_s [\mu_{w,s}^d(k) + \mu_{w,-s}^d(k)] + \alpha \tau(k)]} \quad (4-9)$$

$$\varphi_w(k) = \frac{\sum_d [\mu_{w,s}^d(k) + \mu_{w,-s}^d(k)] + \beta}{\sum_d [\sum_s [\mu_{w,s}^d(k) + \mu_{w,-s}^d(k)] + \beta]} \quad (4-10)$$

$$z_d \sim \sum_{k=1}^K \theta_d(k) \delta(z_d, k) + \theta_d(K+1) \delta(z_d, K+1) \quad (4-11)$$

归纳以上推导过程，基于窗口的 HDP 消息采样传递算法模型的训练过程的伪代码如下表 4-3 所示。

表 4-3 WHDP 模型算法伪代码

Algorithm 1 : 基于窗口的 HDP 消息采样传递算法模型算法

输入: $\alpha, \beta, \gamma, N, s_w, s_m, x_{w,d}$;

输出: θ_d, φ_w ;

1.初始化 $n_k, \tau, \mu_{w,s}^d(k), K$

2.循环迭代

3. For $d = 1$ to D do

4. For $w = 1$ to W do

5. For $k = 1$ to $K - 1$ do

6. 计算 $\mu_{w,s}^d(k)$;

7. 计算 $\mu_{w,s}^d(K')$;

8. $z_d \sim \mu_{w,s}^d$;

9. If $s_k == K$

10. $k = K + 1$;

11. 更新 τ, μ ;

12. n_{k++} ;

13. For $k = 1$ to $K - 1$ do

14. If $n_k == 0$

15. $k = K - 1$;

16. 更新 τ, μ ;

17. Else

18. $n_k = 0$

19. For $k = 1$ to $K - 1$ do

20. 更新 τ, μ ;

21. 直到遍历完成

22.输出: θ_d, φ_w

23.End

4.1.3 WHDP 采样消息传递模型的实验分析

(1) 数据集

同 3.2 节构建的数据集。其中训练集、验证集和测试集按 8: 1: 1 的比例进行划分。

(2) 评价标准

① 混淆度 (Perplexity, perp)

评价主题模型在未知数据集上建模性能如何经常采用混淆度^[23]这一指标, 故本实验也采用混淆度作为评判标准来衡量模型的表现。混淆度值越低, 就表明泛化能力更强, 其预测能力更优越。其计算公式如下式 (4-12):

$$perp = exp \left\{ - \frac{\sum_{w,d} x_{w,d} \log [\sum_k \theta_d(k) \phi_w(k)]}{\sum_{w,d} x_{w,d}} \right\} \quad (4-12)$$

② 文本相似度

实验中通过 TF-IDF 算法来计算不同模型间得到的主题词的相似度, 若改进后的主题模型与其他主题模型之间分别进行主题词提取, 结果相似度越大, 则说明改进后的 WHDP 采样消息传递模型提取出的主题词越准确, 验证本改进后的模型具有实际应用效果。

(3) 参数设置

参考文献^[23]中的参数, 本实验设定参数 α 、 β 、 γ 取值均为 0.01。用 S_w 和 S_m 分别表示窗口的和位移的大小, 他们均属于观测变量, 其取值会影响模型的性能, 所以要先通过控制变量的实验确定 S_w 和 S_m 的取值, 再进行与其他算法的对比实验。

图 4-3 中的(a)图是 WHDP 采样消息传递算法模型混淆度随位移的变化关系, 展示了其在两种不同数据集上的实验效果。在实验中, 预设窗口大小 $S_w = 140$, 迭代次数 $Iter = 40$ 。分析实验结果可知随着 S_m 逐渐增大, 混淆度的值逐渐减小, 当 S_m 增大到 S_w 的 1/2 左右时, 混淆度的变化逐渐趋于平稳, 再当 S_m 接近于 S_w 的值时, 混淆度的值开始收敛。




图 4-3 混淆度变化曲线: (a)混淆度随 S_m 变化曲线; (b)混淆度随 S_w 变化曲线

WHDP 采样消息传递算法模型混淆度随着窗口大小 S_m 变化的关系如图 4-3 中(b)图所示,展示了其在两种不同数据集上的实验效果。在实验中,预设位移 $S_m = 40$,迭代次数 $Iter = 40$ 。分析实验结果可知只有当 S_w 足够大时,混淆度才趋于收敛。而随着 S_w 的值减小,混淆度也随之减小,这时模型的泛化能力才逐渐增强,可见将文档进行切割,细分为更细碎的部分具有相当的实际意义。

(4) 实验结果分析




图 4-4 多模型混淆度对比分析: (a)训练集; (b)测试集

如图 4-4 中的(a)(b)两幅图表是分别在训练集、测试集两个数据集上进行的, WHDP 采样消息传递算法模型与 HDP、LDA、SWTM 模型的混淆度比较实验。首先我们预先设置了一些模型参数,例如 $Iter = 40$, $S_w = 60$, $S_m = 30$, $K = \{10, 20, \dots, 140\}$ 。观察图中信息,可以清晰看出在(b)图测试集上 WHDP 采样消息传递算法模型的混淆度比其他所有方法都小,故该模型效果更好,有更好的预

测能力，有更强的泛化能力。




图 4-5 WHDP 模型 500 次实验主题分布: (a)训练集; (b)测试集

图 4-5 是 WHDP 模型在不同数据集上重复 500 次实验生成的主题数分布，对比图 4-4，可以看出图 4-4 中的(a)(b)当 SWTM 模型在训练集上趋于收敛时主题数接近 60，在测试集上趋于收敛时主题数接近 80，WHDP 模型自动确定的主题数范围接近于 SWTM 模型混淆度趋于收敛时的最佳主题数范围。

表 4-4 显示了 WHDP 模型在数据集上推断出的部分主题的部分词语。

表 4-4 WHDP 模型在数据集上采集到的主题下的词语

主题（部分）	词语（部分）
金融投资	贸易 市场 公司 合作 共赢 发展 经济 投资
风控管理	监管 制度 禁止 洗钱 拦截 人脸 语音 大额
理财产品	增长 回本 收益 过剩 配置 对冲 稳健 经理
功能模块	点击 便利 复杂 速度 超时 市场 手机 服务

如图 4-6 中的(a)(b)两幅图表是分别在训练集、测试集两个数据集上进行的，WHDP 采样消息传递算法模型与 HDP、LDA、SWTM 模型的相似度比较实验。根据实验数据可以分析出在同一主题单词中，WHDP 采样消息传递算法模型与其他模型的相似度均可达到 60%以上，甚至有高达 97%的情况。可以推断 WHDP 采样消息传递算法提取的主题与其他模型提取的主题差异化小，相似度高，能准确有效地提取主题，证明该模型的改进方法是可行的，具有实际应用意义。




图 4-6 多模型相似度对比分析: (a)训练集; (b)测试集

4.2 基于中心词的 HDP 采样消息传递模型

4.2.1 CHDP 采样消息传递模型

4.1 节的 WHDP 采样消息传递算法模型在文本中对单词主题概率进行计算时通过引入窗口这个概念保证单词的顺序性,但对于一定窗口范围内的单词,它们依旧离不开“词袋”假设。本小节进而引入了中心词的概念,提出基于中心词的 HDP 采样消息传递 (Centroid-word based Hierarchical Dirichlet Process, CHDP) 模型。其主要思路是:在推导单词的主题概率分布时将窗口范围内的语义信息也纳入计算。以该词为中心,将窗口范围设定在紧邻该词的数个词内,既能维持单词间的局部有序性,又能保证囊括同个单词在不同上下文环境时的语义信息,保留了单词涉及到的所有主题信息。

4.2.2 CHDP 采样消息传递模型的近似推理方法

图 4-7 是基于中心词的 HDP 采样消息传递模型的因子图。




图 4-7 CHDP 采样消息传递模型因子图

其中符号的详细解释见表 4-5。

表 4-5 CHDP 模型因子图符号含义对照

符号	含义
z	主题
c	上下文信息
d	当前文档
w	当前单词
z_w^d	当前单词的主题
$z_{w,-c}^d$	除 c 外所有单词的主题
$z_{-w,c}^d$	除 w 外所有其他单词的主题
$z_{w,c}^{-d}$	除 d 外其他文档中 w 的主题
c_w^d	上下文语义信息
$\theta_{c_w^d}$	d 中 c_w^d 关于主题的因子
$\mu_{w,c}^d(k)$	w 的主题概率分布
$\mu_{w,-c}^d(k)$	除 c 外 w 的主题概率分布
$\mu_{-w,c}^d(k)$	c 中除 w 外的主题概率分布
$\mu_{w,c}^{-d}(k)$	所有其他文档的 c 中 w 的主题概率分布

续表 4-5 CHDP 模型因子图符号含义对照

符号	含义
$\mu_{w,-c}^d(k)$	除 c 和 w 外其他单词的主题
$\mu_{w,-c}^d(k)$	其他文档中除 c 和 w 外其他单词的主题
θ_d	文档 d 的主题分布
φ_w	文档 d 的主题单词分布

根据因子图可以看出, $\mu_{w,c}^d(k)$ 受 $\mu_{w,c}^{-d}(k)$ 、 $\mu_{w,-c}^d(k)$ 和 $\mu_{-w,c}^d(k)$ 三者共同影响。故可得到各类情况主题概率分布的更新迭代公式分别如下式 (4-13)、式 (4-14)、式 (4-15)、式 (4-16) :

$$\mu_{w,c}^d(k) = \frac{\mu_{w,c}^d + \alpha\tau(k)}{\sum_k [\mu_{w,c}^d + \alpha\tau(k)]} \frac{\mu_{w,c}^{-d}(k) + \mu_{w,c}^d(k) + \beta}{\sum_w [\mu_{w,c}^{-d}(k) + \mu_{w,c}^d(k) + \beta]} \quad (4-13)$$

$$\mu_{w,-c}^d(k) = \sum_{-c} \mu_{w,-c}^d(k) \quad (4-14)$$

$$\mu_{w,c}^{-d}(k) = \sum_{-d} \mu_{w,c}^{-d}(k) \quad (4-15)$$

$$\mu_{-w,c}^d(k) = \sum_{-w} \mu_{-w,c}^d(k) \quad (4-16)$$

可推算得 θ_d 和 φ_w 的更新迭代公式为式 (4-17)、式 (4-18) :

$$\theta_d(k) = \frac{\mu_{w,-c}^d(k) + \mu_{w,c}^d(k) + \mu_{-w,-c}^d(k) + \mu_{-w,c}^d(k) + \alpha\tau(k)}{\sum_k [\mu_{w,-c}^d(k) + \mu_{w,c}^d(k) + \mu_{-w,-c}^d(k) + \mu_{-w,c}^d(k) + \alpha\tau(k)]} \quad (4-17)$$

$$\varphi_w(k) = \frac{\mu_{w,-c}^d(k) + \mu_{w,c}^d(k) + \mu_{-w,-c}^d(k) + \mu_{-w,c}^d(k) + \beta}{\sum_k [\mu_{w,-c}^d(k) + \mu_{w,c}^d(k) + \mu_{-w,-c}^d(k) + \mu_{-w,c}^d(k) + \beta]} \quad (4-18)$$

根据以上推导, 可得基于中心词的 HDP 消息采样传递算法模型的训练过程伪代码如下表 4-6 所示。

表 4-6 CHDP 模型算法伪代码

Algorithm 2 : 基于中心词的 HDP 消息采样传递算法模型算法

输入: $\alpha, \beta, \gamma, N, x_{w,d}$;

输出: θ_d, φ_w ;

1. 初始化 $\mu_{w,s}^d(k), K$

2. 循环迭代

3. For $d = 1$ to D do

4. For $w = 1$ to W do

5. For $i = 1$ to c_w^d do

6. 计算 $\mu_{w,c}^d(k)$;

7. 更新 $\mu_{w,-c}^d(k), \mu_{w,c}^{-d}(k), \mu_{w,c}^d(k)$;

8. 直到遍历完成

9. 输出 θ_d, φ_w

10. End

4.2.3 CHDP 采样消息传递模型实验分析**(1) 数据集**

同 4.1 节数据集。

(2) 评价标准

同 4.1 节评价标准。

(3) 参数设置

用 c_f 和 c_b 分别表示一个窗口中单词在当前位置前半部分和后半部分所含数。他们两个均属于观测变量，其取值直接影响模型的性能。需要先通过控制变量的方法进行试验，确定两个参数的取值。

图 4-8 的(a)图是 CHDP 采样消息传递模型混淆度随 c_f 大小变化的关系，展示了其在两种不同数据集上的实验效果。预设迭代次数 $Iter = 20$ ， $c_b = 20$ 。分析

实验结果,观察到只有当 c_f 不断减小时,混淆度才会随之减小。因此,本模型中 c_f 的值越小,在新语料上的效果越好,泛化能力才能更好,预测能力才能更强。




图 4-8 混淆度变化曲线: (a)混淆度随 c_f 的变化曲线; (b)混淆度随 c_b 的变化曲线

图 4-8 的(b)图是 CHDP 采样消息传递模型混淆度随 c_b 变化的关系,展示了其在两种不同数据集上的实验效果。我们预设参数 $Iter = 20$, $c_f = 20$ 。分析实验结果,观察到只有当 c_b 不断减小时,混淆度才会随之变小。因此,本模型想要提升其在新语料上效果, c_b 的取值要越小。

通过实验对比分析,参数 c_f 、 c_b 的取值越小,也就是以该词为中心向前后扩展的范围越小,范围内的词语关联性更强、相关度越高,模型性能提升,也证明了 CHDP 采样消息传递模型是有实际应用意义的。故在后续的对比实验中,可以将参数 c_f 、 c_b 的值设置为 20。

(4) 实验结果分析

如图 4-9 中(a)(b)两幅图表分别是在训练集、测试集两个数据集上进行的,CHDP 采样消息传递模型与其他模型的混淆度对比实验。在参数预设方面,设置 $Iter = 40$, c_b 、 c_f 均为 20, $K=\{10, 20, \dots, 140\}$ 。分析实验结果,可以清晰看出在测试集上本模型的预测混淆度均小于其他方法,从而得出与其他几种模型相比,该模型的预测能力更优秀,泛化能力更强的结论。




图 4-9 多模型混淆度对比分析: (a)训练集; (b)测试集




图 4-10 CHDP 模型 500 次实验的主题分布: (a)训练集; (b)测试集

图 4-10 是 CHDP 模型在不同数据集上重复 500 次实验生成的主题数分布，对比图 4-9，很明显图 4-9 中的(a)(b)当 CCTM 模型在训练集上趋于收敛时主题数接近 60，在测试集上趋于收敛时主题数接近 80，CHDP 模型自动确定的主题数范围基本与 CCTM 模型混淆度达到平稳状态时的最佳主题数范围一致。

表 4-7 显示了 CHDP 模型在数据集上推断出的部分主题的部分词语。

表 4-7 CHDP 模型在数据集上采集到的主题下的词语

主题（部分）	词语（部分）
金融投资	金融 市场 公司 改革 共赢 发展 经济 投资
风控管理	推进 制度 禁止 洗钱 拦截 人脸 语音 银行

续表 4-7 CHDP 模型在数据集上采集到的主题下的词语

主题（部分）	词语（部分）
理财产品	首发 回本 收益 产品 配置 对冲 份额 经理
功能模块	点击 便利 开发 速度 机构 市场 手机 服务

图 4-11 中(a)(b)两幅图表分别是在训练集、测试集两个数据集上进行的, CHDP 采样消息传递模型与其他模型的相似度比较实验。在参数预设方面, LDA 与 CCTM 模型的主题数为 $K = 60$, CHDP、CCTM 这两个模型的 c_b , c_f 均为 20。分析结果得出在同一主题单词中, CHDP 采样消息传递模型与其他模型的相似度可以达到 65%以上, 甚至有高达 98%的情况, 可见使用本模型提取的主题较为准确, 有一定的实际应用意义。




图 4-11 多模型间相似度对比分析: (a)训练集; (b)测试集

4.3 本章小结

在本章节中, 介绍了两种改进的主题模型, 分别是 WHDP 采样消息传递模型和 CHDP 采样消息传递模型。通过控制变量的实验动态调整模型参数, 找到了预测和泛化能力最好的参数来构建基础模型。并将该模型与其他几种主流的主题模型进行对比实验, 以验证本章提出的两种改进模型的实际可行性以及在实际应用中的应用意义。

第五章 构建情感分析模型

本文使用情感分析算法计算文档的情感倾向性,通过实验比对基于情感词典、基于预训练模型与基于大模型的三种方式,选择最优方法。本章阐述三种方法的主要原理与基本模型,通过实验进行对比与分析,得出结论:基于情感词典的方法有很强的不确定性,结果的准确率会因为情感词典的变化而产生大幅波动,而基于大模型的方法又有语料库不丰富、中文乱码等很大的局限性,因此最终选定基于预训练模型进行情感分析。

5.1 基于情感词典的情感分析方法

5.1.1 模型原理

有关统计学思想的算法中,其中一种就是基于情感词典的情感分析方法,如图 5-1 所示是该方法的主要流程,首先对获取的舆情文本进行清洗和分词处理,随后通过与情感字典进行比对,逐个扫描,识别并提取出文本中的情感词,遍历累加每个情感词对应的分值,最终计算得到段落的情感值,得出情感分类结果。



图 5-1 基于情感词典的文本情感分类方法

但中华文化博大精深,能表达情感的词语数不胜数,情感词典无法囊括所有词语及其情感极性,再比如遇到选取的情感词匹配情感词典失败的情况时只能通过间接方法计算,一般间接计算可以采用与该词最相似的词语的情感词乘以两者相似度的方法,因此本方法还存在很多改进空间。

此外,程度副词、表达否定意思的词、标点符号(如感叹号、省略号、问号)等暗含情感的元素也在一定程度上影响对文本的情感倾向的判断。如“好”、“很好”、“非常好”、“不好才怪”、“好?”,“烂”、“好烂”、“烂炸了”。上面这些例子每个表达的情感程度都不尽相同,甚至一个标点符号就能让一句话

的意思发生翻天覆地的变化。这些因素在计算文本的情感值时都需要被考虑到。

5.1.2 实验分析

(1) 数据集

同 4.1 节数据集。

(2) 评价标准

① 准确率 (Accuracy)

评价情感分析算法的好坏时,我们通常采用准确率这一指标来衡量所有文本中正确预测的文本的占比。准确率越高,则说明分类器的能力越强,分类效果越好。

② 损失函数 (Loss Function)

这一类函数被用来计算预测值和真实值之间的差值,差值越小,证明模型越成功。在本文实验中选择交叉熵损失函数 (Cross Entropy Loss), 计算公式如下式 (5-1)。

$$H(p, q) = - \sum_x (p(x) \log q(x) + (1 - p(x)) \log (1 - q(x))) \quad (5-1)$$

(3) 参数设置

情感词典分别选用标准情感词典与 3.2 节构建的银行专属情感词典。标准情感词典为大连理工大学情感词典。

(4) 实验结果分析

根据实验结果显示,在训练集上,基于标准情感词典的分析准确率为 65.7%, 基于银行专属情感词典的分析准确率为 70.4%, 两者之差仅为 4.7%, 相差不大; 在验证集上,基于标准情感词典的分析准确率为 67.7%, 基于银行专属情感词典的分析准确率为 71.1%, 差距为 3.4%。可见基于构建的银行专属情感词典的模型在准确率上有所提升,但效果不够显著。

5.1.3 局限性

(1) 情感词典的质量直接影响该分类方法的准确性,我们需要考虑如何在

高昂的人力成本与高质量的情感词典之间找到一个平衡点。

(2) 专业领域间的词汇有很强的壁垒，跨领域应用情感词典效果往往差强人意。

(3) 中华文化博大精深，词汇蕴含丰富内涵，对于意思和情感的表达具有很强的灵活性，还可以通过多种形式表达同一种意思。遇到譬如疑问句、双重否定句，抑或是平淡的根本没有任何情感词汇的叙述时，该方法就“失灵”了。例如夏目漱石的名句——“今晚的夜色真美”，这种隐晦的情感表达其情感倾向是难以单凭词和语法来判定的。

5.2 基于预训练模型的舆情文本情感分类方法

5.2.1 预训练编码器

BERT 是一个基于 Transformer 编码器基础上的模型^[4]。其输入构成^[38]如图 5-2 所示。




图 5-2 BERT 文本嵌入

BERT 可使用无监督学习进行预训练，通常采用如下两种方法：

(1) 遮罩语言模型 (Masked LM, MLM)

在预训练中，BERT 会随机选择文本中 15% 的词汇进行遮蔽，并采用以下方式进行处理：10% 的词汇保留其原始形式；10% 的词汇随机替换成其他任意词汇；80% 的词汇用 [MASK] 的方式进行替换。在执行预测任务时，模型对该位置的词汇正确与否有不确定性，这促使模型更多依靠上下文信息进行预测，从而增强其纠错能力。

(2) 下一句预测任务 (Next Sentence Prediction)

BERT 使用二分类来理解文章中两个句子间的关系，通常是判断第二句话在文本中是否紧跟前一句话。对于任一个句子 A，一半概率的 B 是 A 的真正下文，另一半是随机抽取的，通过这样的方式能更准确的刻画句子甚至文档的语义信息。

5.2.2 BAG 模型设计




图 5-3 BGA

BERT 模型在预训练中便使用了大量的语料，词嵌入效果得到了很大的提升。相比词向量 (Word2Vec) 模型而言，或许将 BERT 作为词嵌入层在一定程度上可以取得更出色的效果。使用 BiGRU 对文本的上下文进行特征抽取，可以在不损失准确性的前提下提升训练速度。再加之残差连接，也就是在输入 Attention

层时将 Bi-GRU 的输出结果与原始词向量信息结合^[45], 最后得到分类结果。故本小节采用这种方法进行试验, 试图构建一种如图 5-3 所示的临时取名为 BGA (BERT-GRU-Attention) 的新的舆情文本情感分类模型。

5.2.3 BAG 模型实验分析

(1) 数据集

同 4.1 节数据集。BERT 嵌入层采用构建好的金融领域专业情感词典。

(2) 评价标准

同 5.1 节评价标准。

(3) 参数设置

参考文献^[29]中的参数, 本实验设定嵌入层的 dropout 参数为 0.2, 随机屏蔽输入的 20%。

(4) 实验结果分析




图 5-4 (a)BGA 模型准确率变化曲线; (b)BAG 模型损失值变化曲线

依照图 5-4 的呈现, (a)图展示了 BGA 模型随迭代次数变化的准确率。首先我们关注训练集上的曲线变化, 可以清楚地观察到随着迭代次数增加, 准确率呈逐步上升状态, 且是稳步上升; 然后看验证集上的曲线变化, 转折点发生在第三次迭代后, 准确率在这之前还再持续攀升, 但在此之后就震荡下降。我们可以推断, 验证集上本模型准确率在第三次迭代时达到最大值, 若再进行迭代将陷入过拟合, 准确率反而下降。

BAG 模型损失函数的变化趋势如图 5-4(b)图所示,展示了它随迭代次数变化而发生的变化。根据实验结果,我们可知,在训练集上,随着迭代次数增加,模型的损失函数值逐步下降,且基本是稳步下降,没有什么波动;然而,在验证集上的情况却不尽相同。转折点出现在第三次迭代后,在这之前损失函数值持续下降,但在此之后重新升高。可以得出结论,在验证集上,本模型的损失函数在 Epoch=3 时达到最低点,继续增加迭代次数将造成模型过拟合的后果,损失函数值反而升高,这趋势同准确率变化趋势相一致。

如图 5-5(a)图,展示了本文改进的 BGA 模型与上文提到的 5 种目前主流模型的准确率变化曲线,我们可以清晰地观察到相较其他模型而言,本模型的准确率均优于其他模型,有显著提升。可见采用 BERT 预训练模型能在词嵌入能力上有更好的效果,且注意力机制在一定程度缓解了长程依赖问题。

如图 5-5(b)图,展示了 BGA 模型与前文提到的 5 大主流模型的损失函数值变化曲线对比情况,可以看出变化情况同准确率变化曲线类似,本模型在损失函数值上基本小于其他模型,表明该模型在性能方面有显著提升,证明在基于 BERT 预训练模型的基础上,引入残差连接和注意力机制可以有效提升文本情感分析的效果,提高情感分析水平。




图 5-5 多模型间对比分析: (a)准确率变化对比; (b)损失函数值变化对比

5.3 基于大模型的舆情文本情感分类方法

5.3.1 大模型设计

结合 Alpaca-Lora 的代码，利用低秩自适应（Low-Rank Adaptation, LoRA）的原理，在冻结原模型 LLaMa-13B 模型的参数情况下，通过新增额外的网络层进行先降维再升维的操作，其原理见图 5-6。训练过程中只训练新增的两个矩阵的参数，而不改变模型的输入输出维度，降低微调成本，提升训练速度。本文临时称之为“舆情分析中文语言模型”。




图 5-6 LoRA 原理示意图

5.3.2 大模型实验分析

（1）数据集

同 4.1 节数据集。

（2）评价标准

同 5.1 节评价标准。

（3）参数设置

初始化 A、B 两个参数，分别采用随机高斯分布与 0 矩阵。

（4）实验结果分析

依照图 5-7 的(a)图呈现，展示了舆情分析中文语言模型随迭代次数变化的准确率。训练集上的准确率随着迭代次数增加，先逐步上升后下降再波动趋于平稳；验证集上的变化相似。转折点发生在第八次迭代，因此本模型准确率在第八次迭

代时达到最大值。我们可以推断,再进行迭代模型将陷入过拟合,准确率反而下降。




图 5-7 (a)舆情分析中文语言模型准确率变化曲线; (b)舆情分析中文语言模型损失值变化曲线

如图 5-7 的(b)图所示,展示了舆情分析中文语言模型随迭代次数变化,损失函数值发生变化的关系曲线。在训练集上,随着迭代次数的增加,模型的损失函数值波动下降,在第九次迭代时达到最低点,随后又波动上升;在验证集上变化趋势相似,但却在第八次迭代时达到最低点。可以得出结论,在验证集上,本模型的损失函数在第八次迭代时取到最小值,继续迭代可能造成模型过拟合,损失函数值反而升高,这趋势同准确率变化趋势相一致。




图 5-8 舆情分析中文语言模型与 BAG 模型对比图

如图 5-8(a)图,对比了舆情分析中文语言模型与 BAG 模型的准确率变化曲线,我们可以清晰地观察到 BAG 模型的准确率基本稳定在 70%-75%之间波动,

远胜过舆情分析中文语言模型。可见采用 BERT 预训练模型作为词嵌入的 BAG 模型在准确率上优于舆情分析中文语言模型。

如图 5-8(b)图,对比了舆情分析中文语言模型与 BAG 模型的损失函数值变化曲线,可以看出变化情况同准确率变化曲线类似,舆情分析中文语言模型在损失函数值上基本大于 BAG 模型,表明该模型在性能方面有所不足,不如 BAG 模型。




图 5-9 舆情分析中文语言模型与 BAG 模型相似度变化图

图 5-9 中表示在训练数据集上,舆情分析中文语言模型与 BAG 模型的相似度比较实验。训练开始时,舆情分析中文语言模型与 BAG 模型的相似度持续上升,在迭代次数 Epochs = 8 时达到最高,随后趋于平稳波动。分析结果可知,前期由于训练微调,提升中文语言模型的准确率,使两模型相似度提升;后因为语料限制致使中文语言模型的准确率难以提升以及 BAG 模型过拟合导致自身准确率下降,最终使相似度降低。可见舆情分析中文语言模型还存在一定的局限性。

5.3.3 局限性

目前,通过探索我们初步建立了有上下文能力可支持中文的舆情分析中文语言模型^[58]。但仍存在待改进的问题:

1. 模型效果问题：语料库的来源主要分为外部与内部。外部语料大多是从相关网站的银行板块爬取的数据，或是其他人已经预处理好的数据集，而内部语料主要是依托用户的意见与建议、用户在手机银行社区板块的发帖与讨论以及用户咨询智能客服的问答对话。由于语料有限，语料库不够丰富与专业，目前的训练效果并不可观，对中文的理解力有限，问答效果不好。如果想训练出能够执行舆情分析领域的任务，还需要大量的语料支持与精调；

2. 训练时间问题：目前仅是初步探索阶段，所使用的数据量并不大，也仅部署了 8 块图形处理器（GPU）。这种条件下进行一次交互约需 30 秒到 1 分钟。要想达到 ChatGPT 那样的效果，需要大量的硬件与算力进行支持，因此也在考虑采购相应的硬件设施；

3. 中文乱码问题：由于交互主要使用中文，时有出现乱码，初步怀疑与中文切词有关，该问题亟待解决；

4. 模型选择问题：目前大模型正在蓬勃发展阶段，模型层出不穷，目前只尝试本地化部署了开源的 Alpaca-Lora 模型作为预研，但真正落地到实际应用仍需要考虑多方因素。

5.4 本章小结

本章叙述了三种基于不同技术的舆情文本情感分析算法，分别构建了基于金融领域银行专属情感词典的分析方法和基于 BERT 预训练模型的分析方法以及基于大模型的分析方法，主要通过对各方法原理的分析、实验结果的评判以及优缺点的比较，决定采用在验证集上准确率能达到 75% 的基于 BERT 预训练模型的情感分析方法进行银行业舆情文本的分析。本章仅在预设初始参数的情况下通过实验挑选出准确率高的算法，但目前的准确率还无法满足真正的舆情分析要求，还需继续加大数据量与迭代次数，进行调参优化，提升准确率与性能，才能更有效的进行舆情文本数据的分析。

第六章 系统的设计与实现

6.1 系统需求分析

根据对目前国内外舆情数据采集与分析系统所包含的功能以及实现技术的调研与分析,一般银行主要是外采第三方机构的系统来使用。这可能涉及到关键信息泄露的风险以及数据采集与分析不够贴合实际应用场景的痛点。本文的核心目标在于设计与实现一个以互联网文本大数据为基础的、适配银行业自发需求的舆情数据采集与分析系统。该系统运用网络爬虫对互联网中的舆情文本数据进行抓取,经过数据清洗后,这些数据将会被用作训练机器学习模型的样本。同时,还会进行主题词提取以及权重分析,从而提升爬虫的抓取精细度,有针对性地控制爬虫爬取内容的方向性,使得能构建更适配金融领域银行专属的情感词典,更加贴合自身需求。且通过情感分析和文本分类技术,形成多维度的分析报告,满足银行业对于外部数据的舆情分析、风险监控的需求,严格按照系统设计开发规范,设计完整的需求模型,实现有效的银行业舆情数据采集与分析系统。

6.1.1 业务流程分析

银行业舆情数据采集与分析的整体业务流程如图 6-1 所示。




图 6-1 银行业舆情数据采集与分析业务过程

银行舆情数据采集与分析业务将借助爬虫技术，在预定的时间和站点定期获取舆情数据。这些数据经过简单的去重处理后，主要信息（如发布时间、IP 地址、用户、标题、文本等关键要素）将被提取并落入数据采集结果表中，成为舆情数据库的一部分。随后，使用经过训练的分析模型对舆情信息进行数据清洗与处理，同时再进行主题提取与情感分析，从海量数据中筛选出有价值的信息，为后续分析做好准备。最后，通过一系列可视化操作，将经过处理的舆情数据以清晰直观的方式呈现，形成分析报告供用户查看与进一步分析。系统用户主要分成两大类，分别拥有经办权限与审核权限。拥有经办权限的用户是系统最主要的用户，负责配置舆情数据采集任务以及查看相应的报告结果；拥有审核权限的用户主要是对配置的信息进行复核，对操作权限进行管理。

6.1.2 系统功能性需求分析

本系统可以划分成以下五大功能模块，对照图 6-2 有：

1、舆情数据采集模块

本用爬虫对互联网上的数据进行采集，获取数据资源。在这个阶段，采集到的数据需要经过一些基本处理，譬如排除与舆情无关的广告等信息，还会删除重复冗余的数据，为后续的分析工作打好地基。

2、舆情数据处理模块

对采集到的数据做中文分词等处理，为后续分析做准备。

3、舆情数据分析模块

此模块是本系统的核心，旨在充分挖掘舆情数据所隐含的信息，主要是使用训练好的模型对处理后的数据进行主题提取，使分析人员能更好地了解当前的舆情信息的讨论热点与主要观点；对处理后的数据进行情感分析，便于分析人员掌握舆情可能的发展方向，从而决定是采取正面引导、不做介入还是控评澄清等某一决策。

4、舆情数据加工模块

按周期自动形成相应报告，还可以根据用户所选指标形成多维度的自定义报

告，便于舆情分析人员根据需要对数据分析结果进行高效利用。

5、舆情信息配置模块

修改关键词设置、爬取范围等，根据业务需求有针对性的爬取相应信息，有选择性地进行分析与监控。




图 6-2 功能模块结构图

6.1.3 系统需求用例

本系统用例旨在描述银行业舆情数据采集与分析系统的功能需求，以系统功能为导向，以系统常见用户为出发点，分析系统的功能模块，规划设计系统功能，此处特别举出审核员（图 6-3(a)）与经办员（图 6-3(b)）的用例图为例。




图 6-3 用例图: (a)审核员用例图; (b)经办员用例图

审核员，也就是系统管理员主要有两大职能，分别是监测管理需求与系统管理需求。就监测管理而言，要求包括但不限于包含日志的维护与管理、数据库的维护与管理、缓存的监控与管理以及资源的分配与监控等；而对系统管理而言，

所需功能要包含用户账户的管理与维护、各项功能的设置与维护还有权限的分配与管理等。

经办员，也就是系统普通用户用例的系统功能需求包括数据采集需求、数据分析需求、配置需求。对于数据采集部分，囊括采集任务浏览、采集结果查询；对于数据分析需求，主要包含分析报告查看；配置需求包含关键词管理、数据采集要求管理。

6.1.4 系统非功能性需求分析

对于银行业内使用的系统，其非功能性需求主要集中在性能、数据安全性和稳定性等方面。这些要求旨在确保系统能够持续平稳地运行；保障数据的安全读写，保护数据的隐私和完整，防止数据泄露与损坏；保证功能的高效完备，能持续地运行而不出现崩溃或中断；确保灾备双活的可靠性，一旦系统出现故障，能快速切换到备用系统继续提供服务，保障服务的连续性；保持移植扩展的可伸缩性，让系统在不断更迭的需求中进行迁移和扩展，满足不断变化的业务需求，从而可以更好地提供服务。此外系统还高度关注用户的使用体验，要求系统界面设计简洁明了、功能完整易用、操作简单流畅，同时还要能够长时间保持运行应用状态，提供持续的服务。系统的非功能性需求对系统质效提出了很高的要求，旨在更好地满足用户使用需求，具体有如下几点：

1、性能需求

要求系统具备良好的性能，确保各项操作能够平稳地进行。该需求主要体现在这三个指标上：第一，用户每笔请求的响应时间长短。该时长一般与系统部署的服务器、当前网络环境和请求数据量级直接相关。通常情况下，响应时间应限制在 200 毫秒以内，以确保用户不会经历过长时间的等待。当响应时间较长时，可以考虑采用倒计时和进度条等工具来展示处理进度，从而缓解用户因等待而产生的焦虑情绪。这种互动方式提供实时反馈，可以让用户感知到系统正在积极处理请求，有效缓解用户的不适，有助于提升用户体验。而超时时间普遍设置在 5 秒，在这个时间内系统应该能够执行一般复杂度的数据查询交易。第二，大量用

户并发访问时吞吐量（Transaction Per Second，TPS）的大小。吞吐量代表一个系统对业务工作量最大限度的处理情况。对于普通交易，TPS 达到 20 即可，但对于高频交易，TPS 应该达到 700 的水平，才能满足用户使用需要。第三，同时能够支持的并发用户数量。同一时间，1000 名用户发起访问时，本系统应当能持续稳定的运转。

可见系统的性能好坏与用户体验直接挂钩，具有良好性能的系统才能保持功能的正常运行，才能稳定高效地服务用户。

2、可靠性需求

一个好的系统，一定是可以可持续运转的，因此本需求主要关注点在于系统产生故障的频次、发生故障的级别、故障的影响范围、故障造成的后果以及故障的修复速度。除了计划中的系统升级与维护版本外，本银行业舆情数据采集与分析系统必须是 7*24 小时一直在线，这就需要制定相应的应急措施与抢修方案，才能确保不间断的进行数据采集、数据分析和舆情预警。当系统出现网络异常或宕机等异常情况，应该能迅速切换到灾备环境，保障系统继续平稳运行，持续为用户提供服务。当系统发生逻辑性问题，出现功能故障，应该能迅速定位问题症结，立即修复，不在大规模范围内影响使用。在用户意外进行违规操作导致数据异常的情况下，系统应该能迅速执行回滚操作，以恢复相关表数据，或清除产生的脏数据，使系统功能恢复正常。针对意外违规操作导致的数据异常，回滚操作和数据清除等措施能够快速恢复数据的完整性和准确性，保证系统继续正常运行。而在面对其他各类故障，比如系统崩溃、服务器故障等情况时，建立应对机制是必要的。这包括故障自动检测和报警机制、备用服务器的自动切换等，以确保在出现故障时系统能够迅速响应，减少服务中断时间。此外，完善的恢复机制也是不可或缺的。这可能涵盖数据库备份与还原策略、系统状态的自动恢复机制等。这样一来，无论是人为失误还是意外故障，系统都能够在最短时间内重新运行起来，保障服务的连续性和可靠性。

所以，对于各种类型的故障，系统都应建立完备全面的应对机制与完善的恢复机制，以确保系统能够在各种情况下保持高可用性，能全天候持续提供可靠的

服务。

3、易用性需求

该需求主要从用户体验角度出发,考虑界面设计的美观性、功能布局的合理性、使用操作的便捷性。通过对页面样式的设计以及对与用户之间的交互的加强,应该做到或者努力做到使用户参与培训或浏览操作手册甚至是直接上手操作,都能迅速使用。

4、安全性需求

该需求强调数据隐私存储和安全传输的重要性,同时涉及用户身份认证与不同用户权限的控制。在执行数据写入时,首先需要对提交的数据进行常规校验,如长度校验、合法性校验、格式校验、非空校验、重复校验等。对文件上传,必须检查文件后缀、文件大小、存放地址等。还必须充分考虑是否会受到 SQL 注入攻击,做好防范。对于读数据时,要充分考虑敏感信息的脱敏以及非必要信息不返回等情况。在用户操作系统时需要准确校验用户的访问权限,还要严格控制用户的操作权限,避免权限滥用、管理混乱。

6.2 系统设计

6.2.1 系统业务架构设计

设计一套银行业舆情数据采集与分析系统,首要任务在于要有效处理好舆情数据的采集和分析。这包括了舆情数据采集任务管理、预处理数据的存储、已处理数据挖掘与分析,以及关键要素搜索和多维展示分析报告等功能。为了提高舆情数据采集的广泛性和舆情分析的准确性,当前的首要任务就是解决在采集与存储大量 web 站点原始信息时的高效性的问题。面对海量的数据,为了提升响应速度,需要充分考虑对待爬取的 URL 列表进行管理,以便更好地利用有限资源。为了优化存储资源的利用,当进行结构化信息提取时,仅保留标题、发布时间、作者以及正文等重要要素,而将其他冗余的广告信息忽略。分析系统将通过分析以上数据的清洗与预处理后的内容,构建模型,从而产生舆情分析结果,进而生成一份舆情分析报告,供舆情管理人员进行深入分析与决策制定。



图 6-4 舆情数据采集与分析系统业务架构

在系统设计中，要充分考虑技术选型、架构设计以及性能优化等方面，确保整个系统能稳定高效地运行，满足需求。本系统业务架构划分为五个层级，如图 6-4 所示。从舆情数据采集参数的配置到舆情数据分析结果的生成进行统一的规划管理，按照舆情数据采集参数的配置项（例如采集周期、采集网站、关键字等），爬虫采集相应舆情数据，再对舆情数据的进行清洗、预处理与计算，得到分析报告与结果等一系列业务层次。

（1）舆情信息配置：用户可以对关键词、采集范围和任务状态等信息进行管理，明确数据采集的内容、范围和进度。此处要注意配置准确的信息，以便迅速找到所需要的数据。

（2）舆情数据采集：通过正则抽取、数据预处理以及数据入库，对网络的海量信息进行采集并清洗，供后续使用。此处需要有任务调度系统，能够有效分配采集任务，监控任务执行状态，并进行优先级管理，确保每个任务都按照优先级和调度策略执行。

（3）舆情数据处理：对舆情数据进行初步处理，提取关键字。此处要将数

据存储到合适的数据库中，以支持后续的分析和查询操作。

（4）舆情数据分析：对舆情数据进行加工处理，分辨出信息的正向和负向情绪，定位信息是对哪一类产品和功能的舆论。此处要使用合适的处理技术，便于更深入了解舆情内容。

（5）舆情数据加工：按照不同的维度，统计生成对应的报告，适用于舆情人员了解预警内容，确定舆情控制方案，以及把控舆论导向。此处要提供多维度数可视化展示，包括趋势分析、关键词云等。

6.2.2 系统技术架构设计

后台技术架构图如图 6-5 所示，主要通过网络爬虫对以新浪财经和东方财富为代表的财经网站的银行板块进行数据采集，使用 JIEBA 中文分词、主题模型、基于情感词典的情感分析等技术对舆情数据进行建模分析。所有相关数据都落入 DB2 数据库，通过临时缓存读写加快数据访问效率，提升数据使用频率。用户可通过浏览器页面可视化查看舆情数据与分析报告，根据分析报告作出研判，提升舆情处理效率。




图 6-5 舆情数据采集与分析系统后台技术架构图

6.2.3 系统部署架构设计

银行业舆情数据采集与分析系统的部署架构设计旨在构建一个灵活、稳定、安全、持续、可靠的平台。计划通过局域网将系统所部署的企业内网硬件服务器、安全防火墙、终端、路由器等对象进行连接，支持企业内部的局域网与广域互联网相连接，构成结构合理、内外网应用隔离、内外网数据互通的计算机网络系统。支持舆情数据分布式、多线程并发的采集。同时舆情分析服务器支持对数据进行分析与传输，抽取关键要素，形成有价值的报告，为分析人员提供便捷的服务。

部署架构设计需要考虑多方面因素，要在成本、性能等方面达到性价比的动态平衡，还需要考虑安全这个重要因素。本系统网络的部署架构见图 6-6，基于分布式技术进行部署，可以大幅度降低数据响应时间和处理时间、提升系统吞吐量，多节点可以降低大量用户的并行访问，确保系统在应对各种突发情况下仍能稳定可靠地提供服务，避免系统宕机。此外，系统采取缓存技术来临时存储高频访问的数据内容。通过读写临时缓存的方式，旨在减轻数据库的负荷压力。此举不仅可以加快响应速度，更能提升数据访问的效率，从而提升用户整体体验。



图 6-6 舆情数据采集与分析系统部署架构图

系统会持续监测用户的使用情况,基于实际应用评估是否需要扩展服务器等资源,以应对系统持续将要面临的负荷挑战。出于对安全方面的考量,可增设路由器设备,不同设备可以借此独立接入网络,不同网络之间可以借此建立连接,增强访问过程中对用户身份的识别能力。同样地,设置有效的防火墙也被视为一种可信可靠的安全防护措施,它通过对数据传输过程进行审查,确保数据传输的安全性,从而抵御恶意攻击和入侵行为。这种措施可以提供额外的保障,确保系统的安全性。

6.2.4 系统功能模块详细设计

本节详细设计了本系统相关功能模块。Web 端的框架设计模式主要采用采用 Spring、React、Hibernate 构成的 MVC 主体框架,各司其职,降低程序耦合度。数据底层采用 DB2 数据库。因此本系统是具有功能覆盖全面、数据采集多样、舆情分析智能、报告更新及时、预警信息灵活等特性。

舆情数据采集与分析的整个过程中,可以按时间顺序、地域分布、年龄分布、情感倾向等多维度统计,以分析报告的形式展现。报告的内容可以涵盖舆情信息发布用户的年龄层次、舆情信息爆发的网际协议(Internet Protocol, IP)地址、舆情信息主要的内容、舆情信息的情感倾向、是否达到预警阈值等内容,持续跟进重点话题与敏感话题的走向等。

(1) 舆情数据采集模块

本模块的功能主要利用爬虫技术根据配置的信息自动的提取网络中一定区域内的数据实现。它是银行业舆情数据采集与分析系统中舆情数据采集的核心,其相关配置很大程度上影响了舆情数据采集的覆盖面以及数据分析的准确率。

1、数据采集流程

爬虫启动后将利用统一资源定位符(Uniform Resource Locator, URL)之间的链接关系来采集一个个网页中的信息,具体过程如下:

1) 开始时,会初始化一个 URL 列表,本文主要是在新浪财经、东方财富等财经类网站的银行板块进行信息提取,构建所有需要提取的网址集合;

- 2) 从首页 URL 开始, 按照顺序次序提取列表中每个 URL 对应页面的内容;
- 3) 在采集过程中, 如果遇到之前未提取过的 URL 地址, 会将其放入待提取的网址集合中, 并更新集合, 以确保没有遗漏任何一个链接;
- 4) 然后, 会基于深度优先的方法来确定接下来要抓取的 URL 队列;
- 5) 反复执行上述步骤, 直到待提取队列中没有剩余的 URL 为止, 完成一次信息提取任务。

2、功能时序设计

如图 6-7 所示是舆情数据采集功能系统时序关系。

用户登录系统使用配置管理功能, 此时表示层发送配置列表的查询请求, 在业务层校验该用户实际操作权限, 通过后才能继续请求配置数据, 数据层处理查询任务后返回配置数据, 业务层调用配置管理模型, 返回配置列表数据, 表示层显示配置列表数据。

用户可以选择新增配置, 使用新增配置功能, 表示层发送新增配置的请求, 经由业务层调用相应方法, 随后返回增加的配置列表信息, 表示层显示新增后的配置列表。

用户触发新增数据采集任务操作, 利用新增的配置策略特性, 填写任务的详细信息并保存。这些信息会被传递到表示层, 由其进行新策略数据的提交。接着, 业务层会对这些数据进行非空和正确性相关校验, 在验证通过后才可以进行数据的提交, 然后数据层负责将这些数据保存起来, 并返回新增策略的保存结果。这个结果再被传递回业务层, 最终呈现在表示层上, 显示数据采集任务列表。




图 6-7 舆情数据采集功能系统时序关系

(2) 舆情数据处理模块

舆情数据处理功能主要是将采集的舆情数据进行脏数据清洗、无效与重复内容过滤、整理并存储的过程。

1、数据处理流程

如图 6-8 所示是舆情数据处理流程。




图 6-8 舆情数据处理流程图

数据分析模块主要是对爬取的信息做划分处理，划分后可以为后续处理提供便利。在这个过程中，主要的技术手段涵盖了 JIEBA 中文分词、主题模型、关键词提取，以及情感词典的构建。以下是具体的步骤：

- 1) 数据读取：开始时，需要读取通过爬虫采集的数据；
- 2) 数据筛选：在数据中排除没有价值的信息，例如广告等；
- 3) 分词与规范化：采用 JIEBA 分词对数据进行分词与去停词和规范化处理；
- 4) 主题词提取：使用 WHDP/CHDP 采样消息传递模型，从经过处理的文本中提取主题词；
- 5) 关键词提取：利用关键词提取的方法，从预处理后的文本中抽取关键词；
- 6) 构建情感词典：将主题词和关键词的内容合并并进行去重，创建新的银行领域情感词典；
- 7) 情感分析：最后，对文本进行情感分析，计算其情感倾向。

2、功能时序设计

如图 6-9 所示是舆情数据处理功能时序关系。




图 6-9 舆情数据处理功能系统时序关系

用户登录系统使用数据处理功能，表示层按用户使用的数据处理具体要求进行请求，业务层将具体的要求发送到数据层，数据层处理相应参数后返回待处理的舆情数据，业务层执行舆情数据处理过程，处理成功后保存舆情数据处理结果，再由数据层返回本次新增的舆情数据处理任务的结果，由业务层返回舆情数据处理结果，表示层更新舆情数据处理结果列表。

与此同时，业务层会按照设定好的时间定时执行舆情数据处理过程，及时处理新捕获的舆情数据，并保存处理结果，数据层定时返回舆情数据处理结果，经由业务层处理后表示层再更新列表页。

(3) 舆情数据分析模块

舆情数据分析模块主要是等待每次数据采集、数据处理、模型输出后,依据结果来进行分析。分析界面上主要会显示本次采集的数据量、数据来源、处理时间、舆情倾向结果、比例等参考值,供专业的舆情分析专员来得出具体结论。

1、数据分析流程

具体流程是首先读取数据,展示文本的情感倾向以及舆情话题,识别热点信息和敏感话题,展示舆情文本关键词和主题词,标记热点话题和敏感话题。

具体流程图如图 6-10 所示。




图 6-10 舆情数据分析流程图

2、功能时序设计

如图 6-11 所示为舆情数据分析功能时序关系。

用户登录系统,使用舆情分析功能,表示层按用户配置的信息经由业务层发送舆情分析请求,数据层接到请求后处理查询任务并返回待分析的舆情数据,加工处理在业务层完成,按照用户需求返回相应内容,表示层最终进行展示。

用户可以根据需求选择相应的分析条件,表示层提交分析条件,业务层根据分析条件进行运算并以合适的形式返回结果,返回分析报告与图表,表示层显示供用户分析。




图 6-11 舆情数据分析功能系统时序关系

(4) 舆情数据加工模块

舆情数据加工模块的功能主要是生成常规的日报、周报与月报，还可以个性化生成自定义报告、预警报告等，对于常规报告，是由用户选取的报告类型所对应的时间段作为周期来反馈，按照一定的维度条件统计该周期内的信息。预警报告则是当舆情情感倾向均值达到设定的阈值条件或舆情热点话题触及敏感话题，自动形成的预警信息。

1、数据加工流程

具体流程是首先读取数据，依据加工条件，按照特定的维度展示舆情分析报告。同时定时调用数据监测任务，当触发预警条件时，返回预警报告。

2、功能时序设计

如图 6-12 所示为舆情数据加工功能时序关系。




图 6-12 舆情数据加工功能系统时序关系

用户登录系统，点击加工条件管理，表示层提交请求，业务层检查当前登录用户实际权限，检查通过后请求加工条件数据，数据层处理查询任务后返回加工条件数据，经由业务层调用相应模型，生成加工条件列表并返回，表示层显示加

工条件列表。

用户点击新增加工条件，表示层发送新增加工条件请求，经由业务层调用相应模型，返回加工条件表单，表示层显示新增加工条件。

用户配置新增数据加工任务，表示层提交请求新增数据加工任务相关配置，业务层请求待加工的数据，返回待加工的舆情数据，业务层调用新增的数据加工任务模型，保存数据加工的数据，数据层返回本次数据加工结果，业务层返回数据加工结果，表示层显示数据加工结果。

业务层定时执行数据监测任务，调用定时任务执行数据监测过程，自发地进行分析运算，当触发配置的预警条件时，保存当前触发预警的相关数据，数据层返回舆情预警报告数据，业务层处理并返回舆情预警结果，表示层更新预警报告。

（5）舆情信息配置模块

本模块的主要功能是管理舆情采集规则，策略配置这一功能是针对各个互联网网站上的各类数据做一个基础划分，然后进行收集和分析。

6.2.5 系统数据库设计

如图 6-13 所示是本系统具体实体连接关系。本系统主要包括用户、配置信息、处理任务、舆情文本、分析报告等实体。其中每个用户都可以管理配置信息，所以用户与配置信息为一对多关系；同样每个用户都可以管理处理任务、分析分析报告，因此用户与处理任务是一对多关系，用户与分析报告也是一对多关系。每一个处理任务可以对所有舆情文本进行处理，因此处理任务与舆情文本是一对多的关系。多个舆情文本可以包含多个配置信息，可以生成一份分析报告，所以舆情文本与配置信息是多对多关系，舆情文本与分析报告是多对一关系，该报告会详细记录数据分析的过程、结果和结论。

。




图 6-13 数据库 E-R 图

下面是数据库表设计。舆情数据采集与分析的数据落入 DB2 数据库中。如下是本文涉及的相关核心数据库表。

1、用户管理表（B_USER_MANAGE）

用户管理表主要存放用户信息及其权限，关键要素见下表 6-1。

表 6-1 用户管理表（B_USER_MANAGE）

列名	描述	类型	长度	主键	索引
BUM_ID	主键 ID	varChar	20	Yes	No
BUM_NUMBER	用户 ID	varChar	20	No	Yes
BUM_USER_NAME	用户名称	varChar	50	No	No
BUM_PASSWORD	用户密码	varChar	50	No	No
BUM_AUTH	用户权限	varChar	50	No	Yes

2、配置表（B_CONFIG）

配置表见表 6-2，主要存放配置的相关信息，包括主键 ID、配置编号、配置名称、启用状态、规则、关键字段、关键字段值。其中关键字段和关键字段值可根据需要增加（如时间-具体时间等），而无需修改表结构，使表的兼容性更强。

表 6-2 配置表 (B_CONFIG)

列名	描述	类型	长度	主键	索引
BC_ID	主键 ID	varChar	20	Yes	No
BC_NUMBER	配置编号	varChar	20	No	Yes
BC_NAME	配置名称	varChar	50	No	No
BC_STATUS	启用状态	varChar	1	No	Yes
BC_RULE	规则	varChar	20	No	No
BC_KEY	关键字段	varChar	50	No	No
BC_CONTENT	关键字段值	varChar	200	No	No

3、数据采集任务表 (B_COLLECT_TASK)

数据采集任务表主要存放数据采集任务相关字段，关键要素见下表 6-3。每个数据采集任务都可以关联配置表中的多个配置策略，灵活复用所有配置。

表 6-3 数据采集任务表 (B_COLLECT_TASK)

列名	描述	类型	长度	主键	索引
BCT_ID	主键 ID	varChar	20	Yes	No
BCT_COLLECT_ID	采集策略 ID	varChar	20	No	Yes
BCT_NAME	采集策略名称	varChar	50	No	No
BCT_START_TIME	任务开始时间	timeStamp	16	No	No
BCT_END_TIME	任务结束时间	timeStamp	16	No	No
BCT_STATUS	启动状态	varChar	1	No	Yes
BCT_CYCLE	执行周期	timeStamp	16	No	No
BCT_CREATE_TIME	任务创建时间	timeStamp	16	No	No
BCT_CONFIG_ID	配置策略 ID	varChar	20	No	Yes

4、数据采集结果表 (B_COLLECT_RESULT)

数据采集结果表见表 6-4，主要存放数据采集结果的字段，包括主键 ID、发

布 IP 地址、发布时间、文本存储地址、入库时间、采集策略 ID。每个数据采集结果都关联一个采集策略，形成一一对应的数据采集任务。

表 6-4 数据采集结果表 (B_COLLECT_RESULT)

列名	描述	类型	长度	主键	索引
BCR_ID	主键 ID	varChar	20	Yes	No
BCR_AREA	发布 IP 地址	varChar	20	No	Yes
BCR_CREATE_TIME	发布时间	timeStamp	16	No	Yes
BCR_PATH	文本存储地址	varChar	50	No	No
BCR_TIME	入库时间	timeStamp	16	No	No
BCR_COLLECT_ID	采集策略 ID	varChar	20	No	Yes

5、数据分析任务表 (B_ANALYSIS_TASK)

数据分析任务表见表 6-5，主要存放的是舆情分析任务的相关字段，包括主键 ID、任务编号、任务名称、任务开始时间、任务结束时间、启动状态、执行周期、任务创建时间、采集策略 ID。每个数据分析任务都可以关联采集策略，形成一一对应的数据分析任务。

表 6-5 数据分析任务表 (B_ANALYSIS_TASK)

列名	描述	类型	长度	主键	索引
BAT_ID	主键 id	varChar	20	Yes	No
BAT_ANALYSIS_ID	分析策略 ID	varChar	20	No	Yes
BAT_NAME	分析策略名称	varChar	50	No	No
BAT_START_TIME	任务开始时间	timeStamp	16	No	No
BAT_END_TIME	任务结束时间	timeStamp	16	No	No
BAT_STATUS	启动状态	varChar	1	No	Yes
BAT_CYCLE	执行周期	timeStamp	16	No	No
BAT_CREATE_TIME	任务创建时间	timeStamp	16	No	No

续表 6-5 数据分析任务表 (B_ANALYSIS_TASK)

列名	描述	类型	长度	主键	索引
BAT_COLLECT_ID	采集策略 ID	varChar	20	No	Yes

6、数据分析结果表 (B_ANALYSIS_RESULT)

数据分析结果表见表 6-6, 主要存放数据分析结果相关的字段, 包括主键 ID、主题词列表、关键词列表、情感值、分析策略 ID。

表 6-6 数据分析结果表 (B_ANALYSIS_RESULT)

列名	描述	类型	长度	主键	索引
BAR_ID	主键 id	varChar	20	Yes	No
BAR_RESULT_ID	分析结果 id	varChar	20	No	Yes
BAR_SUBJECT_WORDS	主题词列表	varChar	200	No	No
BAR_KEY_WORDS	关键词列表	varChar	200	No	No
BAR_EMOTION	情感值	varChar	200	No	No
BAR_ANALYSIS_ID	分析策略 ID	varChar	20	No	Yes

7、数据报告表 (B_DATA_REPORT)

数据报告表见表 6-7, 主要用于存放生成报告所需要的字段, 主要包括主键 ID、报告 ID、报告名称、关键字段、关键字段值、分析策略 ID。其中关键字段和关键字段值可根据需要增加 (如时间-具体时间等), 而无需修改表结构, 提升表的可扩展能力。

表 6-7 数据报告表 (B_DATA_REPORT)

列名	描述	类型	长度	主键	索引
BDR_ID	主键 ID	varChar	20	Yes	No
BDR_REPORT_ID	报告 ID	varChar	20	No	Yes
BDR_REPORT_NAME	报告名称	varChar	50	No	No
BDR_KEY	关键字段	varChar	50	No	No

续表 6-7 数据报告表 (B_DATA_REPORT)

列名	描述	类型	长度	主键	索引
BDR_CONTENT	关键字段值	varChar	50	No	No
BAR_ANALYSIS_ID	分析策略 ID	varChar	20	No	Yes

6.3 系统实现

本章节主要展示本银行业舆情数据采集与分析系统主要功能的页面,如图 8-1 所示为银行业舆情数据采集与分析系统的首页,图 8-2 所示为配置中心页面,图 8-3 为报告中心页面。

6.3.1 系统首页实现

系统控制了不同用户角色的权限,对于不同用户登录后的页面和可使用的功能存在限制,每个用户只能在自己授权的范围内进行操作与使用。进入登录页后输入相应的用户名密码进行登录操作,校验通过,登录成功后默认展示系统首页。系统首页主要包含系统的左侧导航栏、上方标题栏、右上角用户信息、中部主要内容部分,主要内容分为任务中心(图 6-14(a))和报告中心(图 6-14(a))两个 tab 页,可进行切换,任务中心 tab 主要罗列了目前正在进行的数据采集任务列表,报告中心 tab 页主要展示已形成的报告。



图 6-14 银行业舆情数据采集与分析系统首页: (a)首页任务中心; (b)首页报告中心

6.3.2 系统配置中心实现

点击左侧导航栏的配置中心，进入系统的配置中心页，用户可以看到全量采集配置列表，也可通过模糊搜索对相应的报告进行查询。管理所有采集配置的相关信息。可以增删改查配置，并管理配置中的采集范围、采集时间等基本参数。




图 6-15 银行业舆情数据采集与分析系统配置中心页面




图 6-16 行业舆情数据采集与分析系统配置中心: (a)新建策略页面; (b)新建策略新增分期

6.3.3 系统报告中心实现

在系统报告中心页，可以直观地查看某个报告的详细信息。




图 6-17 银行业舆情数据采集与分析系统报告中心页面

6.4 系统测试

银行业系统最讲究的是安全、稳定、可靠，这就少不了全方位的详尽的系统测试，才能及时发现程序上的逻辑错误问题、流程上的越权与重提问题、业务上的流程顺序问题等等，才能确保达到使用便利、系统安全、运行稳定、信息可靠的目标。

6.4.1 测试方法

本文测试过程主要采用以下 3 种测试方法：

1、单元测试

这是一种系统白盒测试，先将系统功能单元划分为具体模块，再对一个个具体模块进行详尽测试，通过断点等方式全面覆盖关键流程，检查系统模块的功能

是否正常，检查程序能否正确执行，查找代码中的错误并进行修复，偏向测定系统内部逻辑问题。

2、功能测试

功能测试属于黑盒测试，依次按照系统的功能模块对每个具体的功能点进行的操作，其目的是验证各项功能是否达到需求要求。这种测试方法旨在确保系统的功能能够正确运行，确定系统的性能表现确实稳定，从而保障整体系统的质量。

在功能测试中，测试人员通过模拟用户的操作，检查每个功能点是否按照预期执行，是否产生正确的输出，以及是否满足相应的功能需求。这样的测试过程有助于发现功能缺陷、错误行为或者不一致之处，从而确保系统能够在各个功能方面正常运行。总的来说，功能测试是保证系统功能正确性的关键步骤，通过验证每个功能点，可以确保系统在满足用户需求和预期功能的基础上保持稳定的性能表现。

3、集成测试

集成测试就是联合各种功能模块一起进行测试，主要针对的是功能模块整体与功能模块之间的变量和函数。通过集成测试可以检查系统功能模块之间的交互与函数调用是否正常，模块之间的信息交互与通讯是否正常。

6.4.2 测试用例

设计测试用例，对每个测试点进行详细的用例描述，通过比对真实测试结果与预期结果的差异，检查隐含的缺陷，对系统的核心功能进行验证。下面主要罗列几个重要功能的测试用例为例：

测试用例 1：采集配置功能模块测试

测试目标：采集配置功能的增删改查等功能测试符合预期结果，完成测试。

表 6-8 采集配置功能的测试用例（部分）

测试用例 ID	测试步骤	预期结果	测试结果
CC-1	进入配置中心页面，未输入筛选条件，全量查询采集配置	查询全量采集配置，以列表形式分页展示结果	成功

续表 6-8 采集配置功能的测试用例（部分）

测试用例 ID	测试步骤	预期结果	测试结果
CC-2	进入配置中心页面，输入策略名称，根据名称模糊匹配对应的采集配置	模糊查询对应采集配置，以列表形式分页展示结果	成功
CC-3	点击新增策略新建任务	出现新增策略的表单	成功
CC-4	校验表单中必输项	出现必输项必填的提示	成功
CC-5	填写内容并保存	提示保存结果	成功
CC-6	点击编辑进入修改页	进入修改页	成功
CC-7	修改策略内容并保存	提示保存结果	成功
CC-8	点击删除	提示删除结果	成功

测试用例 2：采集任务配置功能测试

测试目标：完成采集任务配置的增删改查等功能测试。

表 6-9 采集任务配置功能的测试用例（部分）

测试用例 ID	测试步骤	预期结果	测试结果
CT-1	进入任务中心，未输入筛选条件，全量查询采集任务	查询全量采集任务，以列表形式分页展示结果	成功
CT-2	进入任务中心，输入任务名称，根据名称模糊匹配对应的采集任务	模糊查询对应采集任务，以列表形式分页展示结果	成功
CT-3	点击新增任务	出现新增任务的表单	成功
CT-4	校验表单中必输项	出现必输项必填的提示	成功
CT-5	填写内容并保存	提示保存结果	成功
CT-6	点击编辑进入修改页	进入修改页	成功
CT-7	修改任务内容并保存	提示保存结果	成功
CT-8	点击删除	提示删除结果	成功

表 6-9 采集任务配置功能的测试用例（部分）

测试用例 ID	测试步骤	预期结果	测试结果
CT-9	查看任务执行情况	展示任务执行情况	成功

测试用例 3：舆情报告展示功能测试

测试目标：完成各种筛选条件下的舆情报告展示等功能测试。

表 6-10 舆情报告展示功能的测试用例（部分）

测试用例 ID	测试步骤	预期结果	测试结果
ZS-1	选择展示维度	出现选项列表	成功
ZS-2	选择所需对象	提示选择结果	成功
ZS-3	点击生成报告	提示生成结果	成功
ZS-4	点击查看报告	展示报告内容	成功

6.4.3 测试结果

经过全面测试，本系统各功能模块能正常工作，满足需要。压力测试结果表明 500 人同时访问系统并进行操作，页面可以在 30 毫秒内进行响应，在本系统设计的性能指标要求内。

总结与展望

在网络舆情这种新型社会舆情生态环境下，银行业的舆情风险管理工作面临着极大挑战，一旦掀起舆情风波，银行的信用受到冲击，后果不堪设想。对于一些负面消极的信息需要及时捕获，加强引导，保护品牌名誉，维护公司信誉；对于一些投诉、不满的信息需要尽快把控，分析用户诉求，关注要点痛点，解决相应问题，提升用户的好感度。对潜在的问题提前发出警示，对显现的问题迅速作出响应，方能助力企业获取网络舆情的主导地位，维护公司信誉，增强品牌公信力。同时，还有助于公司充分发挥自身的主观能动性，实现数字化转型，积极迎接金融全球化的挑战。因此，建立银行业舆情数据采集与分析系统，实时获取舆情数据，划分舆情重要等级，辨别舆情情感倾向，提升舆情分析效率，提高舆情应急处置能力是银行业在数字化浪潮时代的首要任务之一。

本系统具有以下几点优势：首先，从数据方面来看，主要针对主流新闻网站、主流财经相关网站等，根据舆情专业技术人员的设定有目的有针对的爬取所需数据。其次，从算法方面来看，基于数据采集与预处理、主题模型提取、银行领域情感词典构建以及情感分析机制，准确进行信息分类与情感分析。再者，操作页面简洁明了，响应速度快，数据展示直观，各类报告定时自动生成，触发阈值以及到达警戒线及时预警等功能，便于用户上手使用，提升舆情分析与处理的效率。运用先进的大数据技术，充分整合银行内外的大数据资源，迅速弥补人工分析的不足，加速推进智能平台和系统的建设进程，打造智能化舆情防控体系。在此过程中，着重构建专属于银行业的舆情数据采集与分析系统，以提升银行的舆情管控能力和信息安全防护水平。

从实际应用情况方面论述，本系统尚在研发初步阶段，目前只能针对舆情数据进行采集与分析，且很多功能待完善。例如，在数据方面，可以加大数据采集的渠道与范围，从小程序、公众号等一系列流量更大的渠道进行采集，采集不仅包括银行板块的其他相关板块内容，挖掘更深层的隐含关系；在模型方面，可以通过更深入的实验与多模型的对比，提升舆情分析模型的准确度、速度等性能，尤其是生成式 AI 正在掀起新一轮产业变革的浪潮，要加快大模型在金融领域的

落地，利用好 ChatGPT 大模型解决客户体验、风险防控等关键方面的痛点；在应用方面，可以引入短信预警功能以及在移动端查看报告等功能，让用户可以随时随地地查看舆情数据监控情况并及时获取预警信息，提升便利性。在功能方面，可以向囊括用户画像、用户偏好分析、用户行为、反诈反洗钱拦截等多位一体的系统扩展，让数据“活”起来，发挥其效能，创造价值。

参考文献

- [1]Blei D M,Ng A Y,Jordan M I. Latent dirichlet allocation [J]. Machine Learning Research Archive,2003,3:993-1022.
- [2]Chen Z,Huang Y,Li J,et al. Improving Mask Learning Based Speech Enhancement System with Restoration Layers and Residual Connection[C]. INTERSPEECH.2017:3632-3636.
- [3]Counting the number of tweets. GigaTweet. 2015.
- [4]Devlin J,Chan M W,Lee K,et al. Bert:Pre-training of deep bidirectional transformers for language understanding[C].//North American Chapter of the Association for Computational Linguistics.2018:4171-4186.
- [5]Dzmitry Bahdanau,Kyunghyun Cho,Yoshua Bengio. Neural Machine Translation by Jointly Learning to Align and Translate.[J]. CoRR,2014,abs/1409.0473.
- [6]Giridhar Kumaran,James Allan. Text classification and named entities for new event detection[P]. Research and development in information retrieval,2004.
- [7]Hochreiter S,Schmidhuber J. Long short-term memory[J]. Neural computation,1997,9(8):1735-1780.
- [8]Hofmann T. Probabilistic latent semantic indexing [C]. ACM SIGIR Forum.ACM,2017,51(2):211-218.
- [9]Hu W , Gu Z , Xie Y , et al. Chinese Text Classification Based on Neural Networks and Word2vec[C]// 2019 IEEE Fourth International Conference on Data Science in Cyberspace (DSC). IEEE, 2019.
- [10]Jennifer Bachner,Kathy Wagner Hill. Advances in Public Opinion and Policy Attitudes Research[J]. Policy Studies Journal,2014,42.
- [11]Johnson R,Zhang T. Deep pyramid convolutional neural networks for text categorization[C]. Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics(Volume 1:Long Papers).2017:562-570.
- [12]Jordan M I. Dirichlet processes,Chinese restaurant processes,and all that[C]. In:

- Proceedings of the Tutorial Presentation at the NIPS Conference. Whistler,Canada:The MIT Press,2005.
- [13]Jun Ma,Zheng Li,Jack C.P. Cheng,Yuexiong Ding,Changqing Lin,Zherui Xu. Air quality prediction at new stations using spatially transferred bi-directional long short-term memory network[J]. Science of the Total Environment,2020,705(C):135771.
- [14]Kar S,Maharjan S,Solorio T. RiTUAL-UH at SemEval-2017 task 5: Sentiment analysis on financial data using neural networks [C]. Proceedings of the 11th International Workshop on Semantic Evaluation(SemEval-2017).2017:877-882.
- [15]Kyunghyun Cho,Bart van Merriënboer,Çaglar Gülçehre,Fethi Bougares,Holger Schwenk,Yoshua Bengio. Learning Phrase Representations using RNN Encoder-Decoder for Statistical Machine Translation.[J]. CoRR,2014,abs/1406.1078.
- [16]Liu D ,et al. Window-Based Topic Model for HDP[C]// 2019 16th International Computer Conference on Wavelet Active Media Technology and Information Processing (ICCWAMTIP). 2019.
- [17]Loeliger H.A. An introduction to factoe graphs[J]. IEEE Signal Processing Magazine,2004,21(1):28-41.
- [18]Mike Thelwall. A web crawler design for data mining[J]. Journal of Information Science,2001,27(5).
- [19]Teh Y W,Jordan M I,Beal M J. Hierarchical Dirichlet processes [J]. Journal of the American Statistical Association,2006,101(476):1566-1581.
- [20]Teh Y W,Jordan M I. Hierarchical Bayesian nonparametric models with applications[C]. Bayesian Nonparametrics Principles and Practice. Cambridge University Press,2009.1-47.
- [21]Thomas Fischer,Christopher Krauss. Deep learning with long short-term memory networks for financial market predictions[J]. European Journal of Operational

- Research,2018,270(2):654-669.
- [22]Thomas S. Ferguson. A Bayesian Analysis of Some Nonparametric Problems[J]. The Annals of Statistics,1973,1(2):209-230.
- [23]Wallach H.M,Mimno D.M,Mccallum A. Rethinking LDA:Why priors matter[C]. Advances in Neural Information Processing Systems 22:23rd Annual Conference on Neural Information Processing Systems 2009. Proceedings of a meeting held 7-10 December 2009,Vancouver,British Columbia,Canada. 2009,1973-1981.
- [24]Yang Ai Min,Lin Jiang Hao,Zhou Yong Mei,Chen Jin. Research on Building a Chinese Sentiment Lexicon Based on SO-PMI[J]. Applied Mechanics and Materials,2012,263-266(263-266):688-1693.
- [25]Yu Sun,Shuohuan Wang,Yukun Li,Shikun Feng,Hao Tian,Hua Wu 0003,Haifeng Wang. ERNIE 2.0: A Continual Pre-training Framework for Language Understanding.[J]. CoRR,2019,abs/1907.12412.
- [26]Yu Sun,Shuohuan Wang,Yukun Li,Shikun Feng,Xuyi Chen,Han Zhang,Xin Tian,Danxiang Zhu,Hao Tian,Hua Wu 0003. ERNIE: Enhanced Representation through Knowledge Integration.[J]. CoRR,2019,abs/1904.09223.
- [27]Zeng Jia,Cheung William K,Liu Jiming. Learning topic models by belief propagation.[J]. IEEE transactions on pattern analysis and machine intelligence,2013,35(5):1121-1134.
- [28]蔡阳. 基于深度学习的用户评论情感分析的方法研究[D].浙江理工大学,2022.DOI:10.27786/d.cnki.gzjlg.2022.000037.
- [29]曹国胜. 基于大数据的网络舆情分析研究[D].浙江海洋大学,2021.DOI:10.27747/d.cnki.gzjhy.2021.000143.
- [30]曾莉,等.基于 LDA 与注意力机制 BiLSTM 的微博舆情分析模型[J].南京理工大学学报,2022,46(06):742-748.DOI:10.14177/j.cnki.32-1397n.2022.46.06.011.
- [31]曾叶. 面向金融舆情分析技术的研究与应用[D].电子科技大学,2020.DOI:10.27005/d.cnki.gdzku.2020.001492.

- [32]常东亚,严建峰,杨璐,刘晓升.基于滑动窗口的主题模型[J].计算机科学,2016,43(12):101-107.
- [33]常东亚,严建峰,杨璐.基于中心词的上下文主题模型[J].计算机应用研究,2018,35(04):1005-1009.
- [34]陈佳.基于大数据的社交网络舆情生态性评价研究[J].信息与电脑(理论版),2021,33(08):196-198.
- [35]陈怡菲,李雨静,肖金兰等.基于大数据技术网络舆情分析系统[J].网络安全技术与应用,2023,(09).
- [36]陈钊,徐睿峰,桂林,陆勤.结合卷积神经网络和词语情感序列特征的中文情感分析[J].中文信息学报,2015,29(06):172-178.
- [37]褚旂旒,孙扬.网络舆情监控系统处理流程及核心功能实现[J].信息技术,2022,(06).
- [38]崔雨萌,王靖亚,刘晓文等.融合注意力和裁剪机制的通用文本分类模型[J/OL].计算机应用:1-13[2023-07-24].<http://kns.cnki.net/kcms/detail/51.1307.tp.20221018.2159.002.html>.
- [39]丁森华,邵佳慧,李春艳,杨枝蕊.文本情感分析方法对比研究[J].广播电视信息,2020(04):92-96.DOI:10.16045/j.cnki.rti.2020.04.028.
- [40]杜宇姗.基于深度学习的多元金融行业舆情风险研究[D].大连外国语大学,2022.DOI:10.26993/d.cnki.gslyc.2022.000267.
- [41]高永兵,杨利莹,胡文江等.基于 HDP 模型的领域微博主题演化研究[J].计算机工程,2018,44(02):1-8.
- [42]何佳,周长胜,石显锋.网络舆情监控系统的实现方法[J].郑州大学学报(理学版),2010,42(01):82-85.
- [43]贺然.互联网舆情监控与分析系统的设计与实现[D].华东师范大学,2017.
- [44]胡家珩.基于深度学习的财经媒介信息情感分析研究[D].南京理工大学,2019.DOI:10.27241/d.cnki.gnjgu.2019.001106.

- [45]黄山成,韩东红,乔百友,吴刚,王国仁.基于 ERNIE2.0-BiLSTM-Attention 的隐式情感分析方法[J].小型微型计算机系统,2021,42(12):2485-2489.
- [46]李合龙,任昌松,柳欣茹等.金融市场文本情绪研究综述[J].数据分析与知识发现,2023,28(02):16-18.
- [47]李明,胡吉霞,侯琳娜等.商品评论情感倾向性分析[J].计算机应用,2019,39(S2):15-19.
- [48]李晓晨.我国网络舆情研究现状与研究成果分析[J].办公自动化,2023,28(02):16-18.
- [49]刘超然.在线新闻网民评论情感倾向性分析及可视化研究[D].哈尔滨工业大学,2018.
- [50]刘小满,王小辉.基于“互联网+”的网络舆情监控系统的设计与实现[J].电脑知识与技术,2019,15(31):37-40.DOI:10.14004/j.cnki.ckt.2019.3658.
- [51]刘阳,高巍,李大舟.基于中文微博的情感分析方法研究[J].沈阳化工大学学报,2019,33(04):362-367.
- [52]陆岷峰,高攀,徐阳洋.金融机构声誉风险管理数字化路径研究[J].区域金融研究,2023,(07).
- [53]欧阳昌海.中小商业银行品牌的舆情管理[J].金融博览,2022(09):62-64.
- [54]钱莉.基于“词-主题”耦合网络的舆情话题演化研究[D].南京邮电大学,2022.DOI:10.27251/d.cnki.gnjdc.2022.000056.
- [55]任文静.基于互联网的数字媒体内容舆情分析系统设计与实现[J].电子设计工程,2020,28(07):82-86.DOI:10.14022/j.issn1674-6236.2020.07.019.
- [56]孙丹丹,郑瑞坤.BERT-DPCNN 模型在网络舆情情感分析中的应用[J].网络安全技术与应用,2022(08):24-27.
- [57]陶思奇,胡爱平,袁硕晨.负面网络舆情对商业银行影响机理及应对措施研究[J].网络安全技术与应用,2023,(09).
- [58]汪寿阳,李明琛,杨昆等.ChatGPT+金融:八个值得关注的研究方向与问题[J].管理评论,2023,35(04):

- [59]王杰,严建峰,刘晓升,杨璐.HDP 采样消息传递算法[J].计算机应用研究,2016,33(07):1994-1998.
- [60]王科,夏睿.情感词典自动构建方法综述[J].自动化学报,2016,42(04):495-511.DOI:10.16383/j.aas.2016.c150585.
- [61]王猛.一种基于狄利克雷过程的主题模型[D].苏州大学,2019.DOI:10.27351/d.cnki.gszhu.2019.003346.
- [62]文博.舆情洞察系统的设计与实现[D].华东师范大学:2020.
- [63]徐子昂.基于 BERT 预处理模型的网络舆情细粒度情感分析[J].现代信息科技,2023,7(03):14-19.DOI:10.19850/j.cnki.2096-4706.2023.03.003.
- [64]许鑫,章成志.互联网舆情分析及应用研究[J].情报科学,2008(08):1194-1200+1204.
- [65]张华平,李林翰,李春锦.ChatGPT 中文性能测评与风险应对[J].数据分析与知识发现,2023,7(03).
- [66]张瑾,段利国,李爱萍等.基于注意力与门控机制相结合的细粒度情感分析[J].计算机科学,2021,48(08):226-233.
- [67]张帅.全文检索技术的研究和应用[D].北京邮电大学,2012.
- [68]赵熠,熊峰.基于 BERT 模型的舆情监测技术应用[J].集成电路应用,2022,39(09):140-141.DOI:10.19339/j.issn.1674-2583.2022.09.059.
- [69]钟涛.互联网舆情分析系统的设计与实现[D].华东师范大学,2018.
- [70]周飞燕,金林鹏,董军.卷积神经网络研究综述[J].计算机学报,2017,40(06):1229-1251.
- [71]周启航,李彤召,张虹,等.关于网络舆情热点主题提取的分析与研究[J].2021,2,142-143.